Concepte și aplicații în Vederea Artificială

Bogdan Alexe
bogdan.alexe@fmi.unibuc.ro

Radu Ionescu
raducu.ionescu@gmail.com

Curs opțional

anul III, secția Informatică, semestrul I, 2020-2021

Cursul trecut

1. Aspecte organizatorice legate de cursul de VA
2. Ce este VA?
3. Aplicații de succes în VA
4. Structura cursului de VA
5. Bibiliografie

Cursul de azi

- Formarea imaginilor
- Prima temă
- Diverse modele pentru zgomot în imagini
  - salt and pepper, impuls
  - Gaussian (normal)
- Filtrarea liniară
  - corelație, convoluție
  - filtre: de medie, Gaussian, accentuare
  - aplicație: imagini hibrid

- Filtrarea neliniară
  - filtrul median

normal

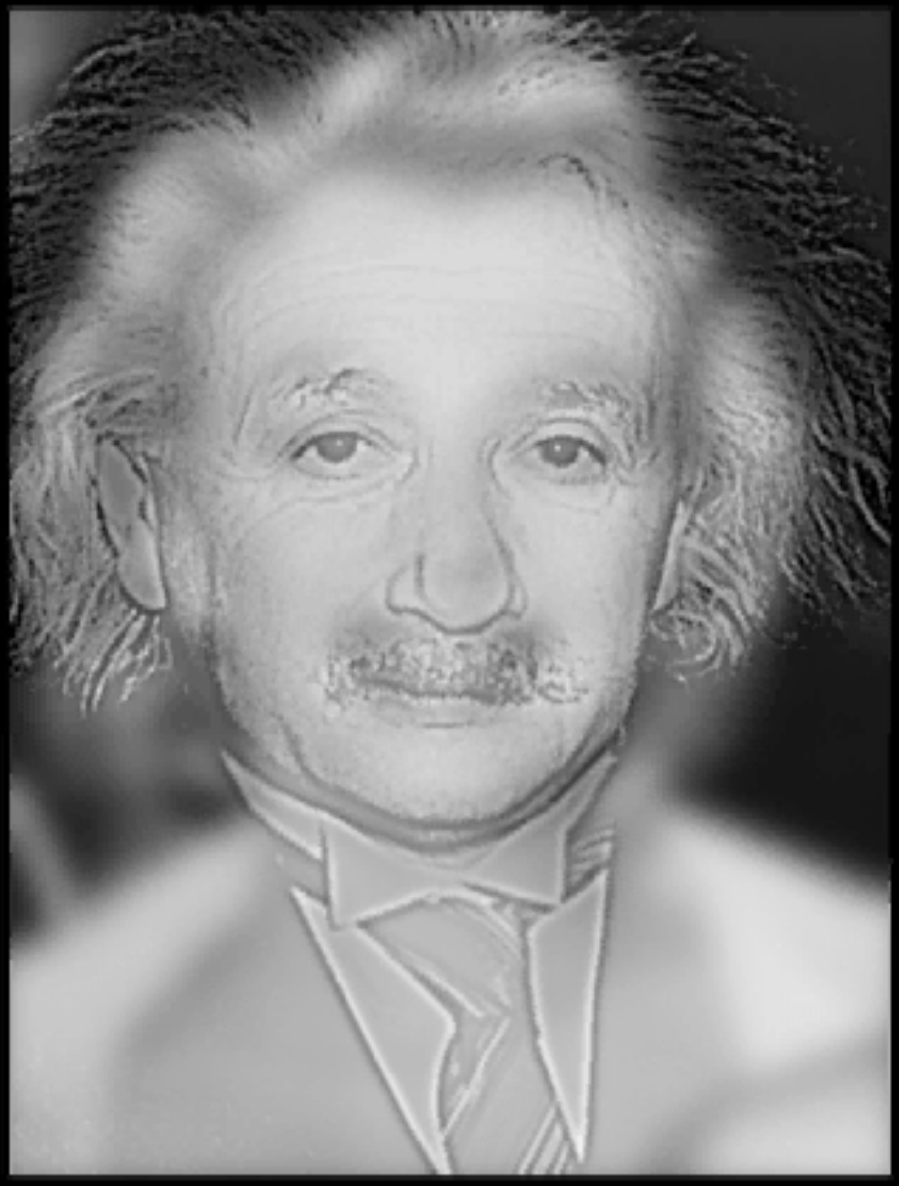

Formarea imaginilor

Formarea imaginilor

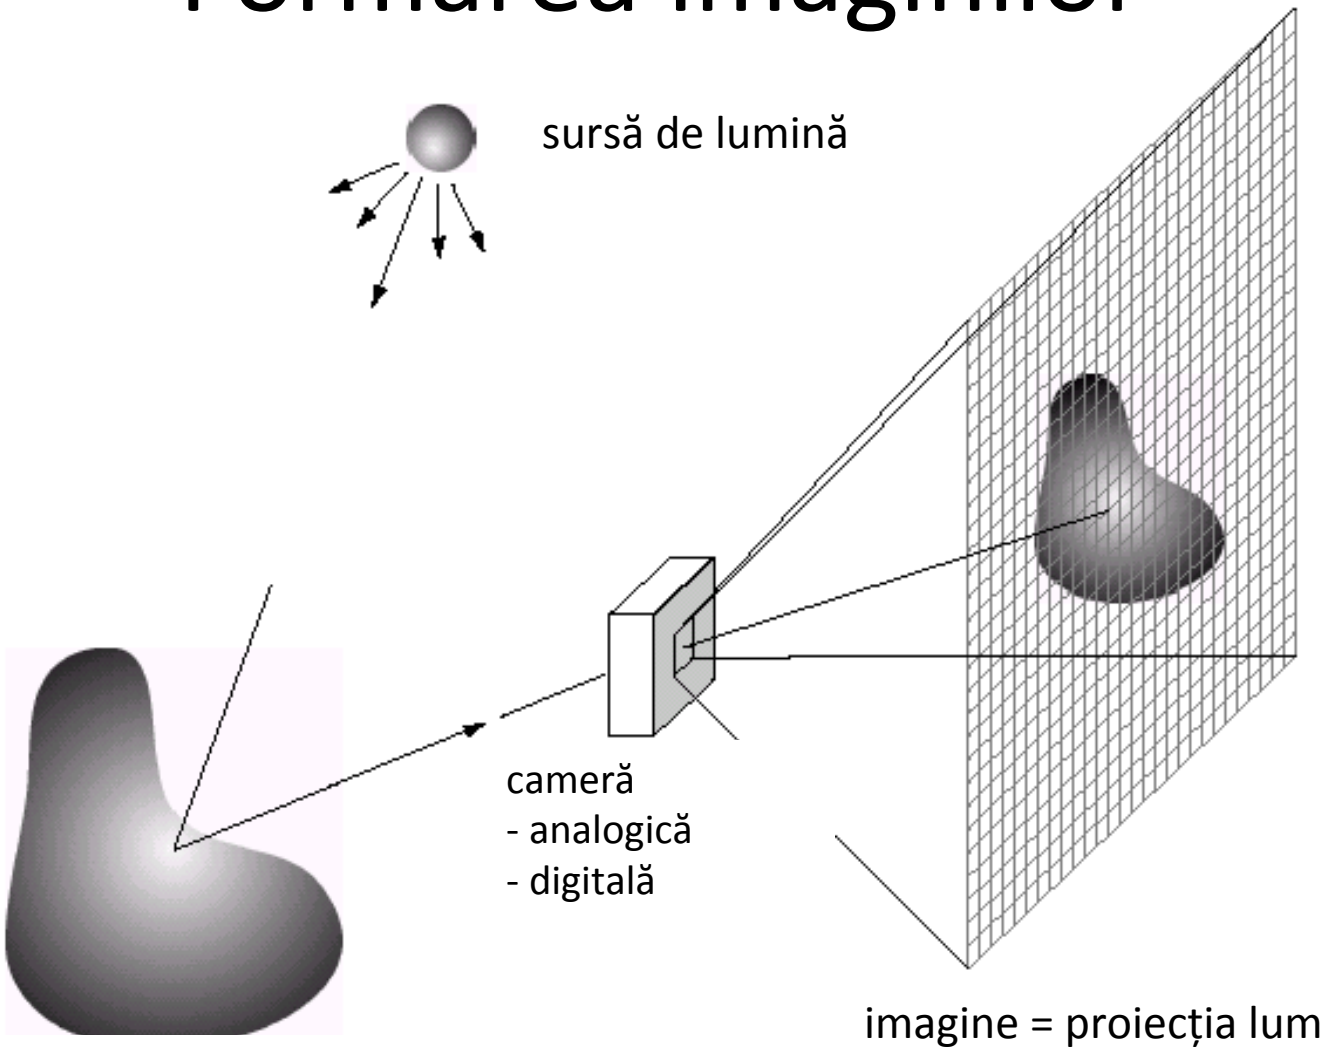

Slide adaptat după Derek Hoiem

Camere digitale

http://electronics.howstuffworks.com/digital-camera.htm

Senzori de imagine:

1. CMOS (complementary metal oxide conductor)
2. CCD (charge couple device)

CMOS

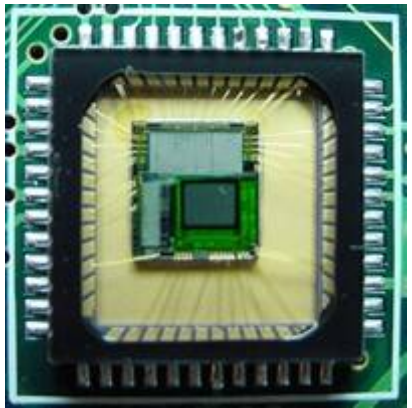

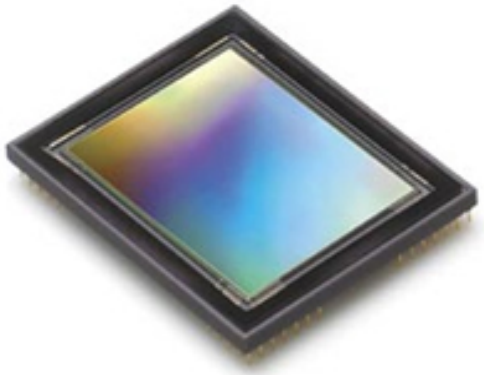

CCD

Slide adaptat după Steve Seitz

Imagini digitale

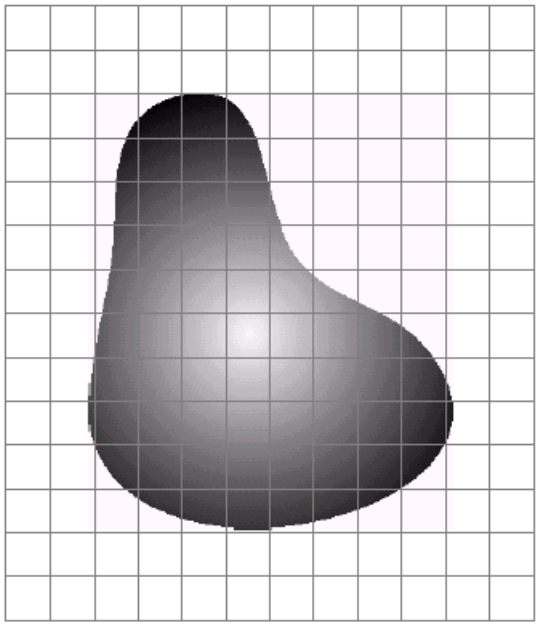

Imagine proiectată pe senzorul de imagine

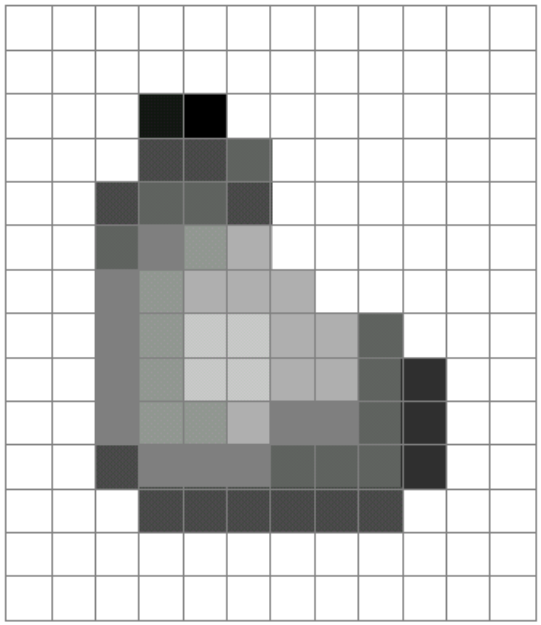

Imagine rezultată în urma discretizării

- eşantionare - discretizează spațiul în pixeli
- cuantizare - discretizează luminozitatea

Imagine digitală = matrice bidimensională; elementele ei se numesc pixeli (pixel = picture element)

Slide adaptat după Derek Hoiem

Imagini digitale color

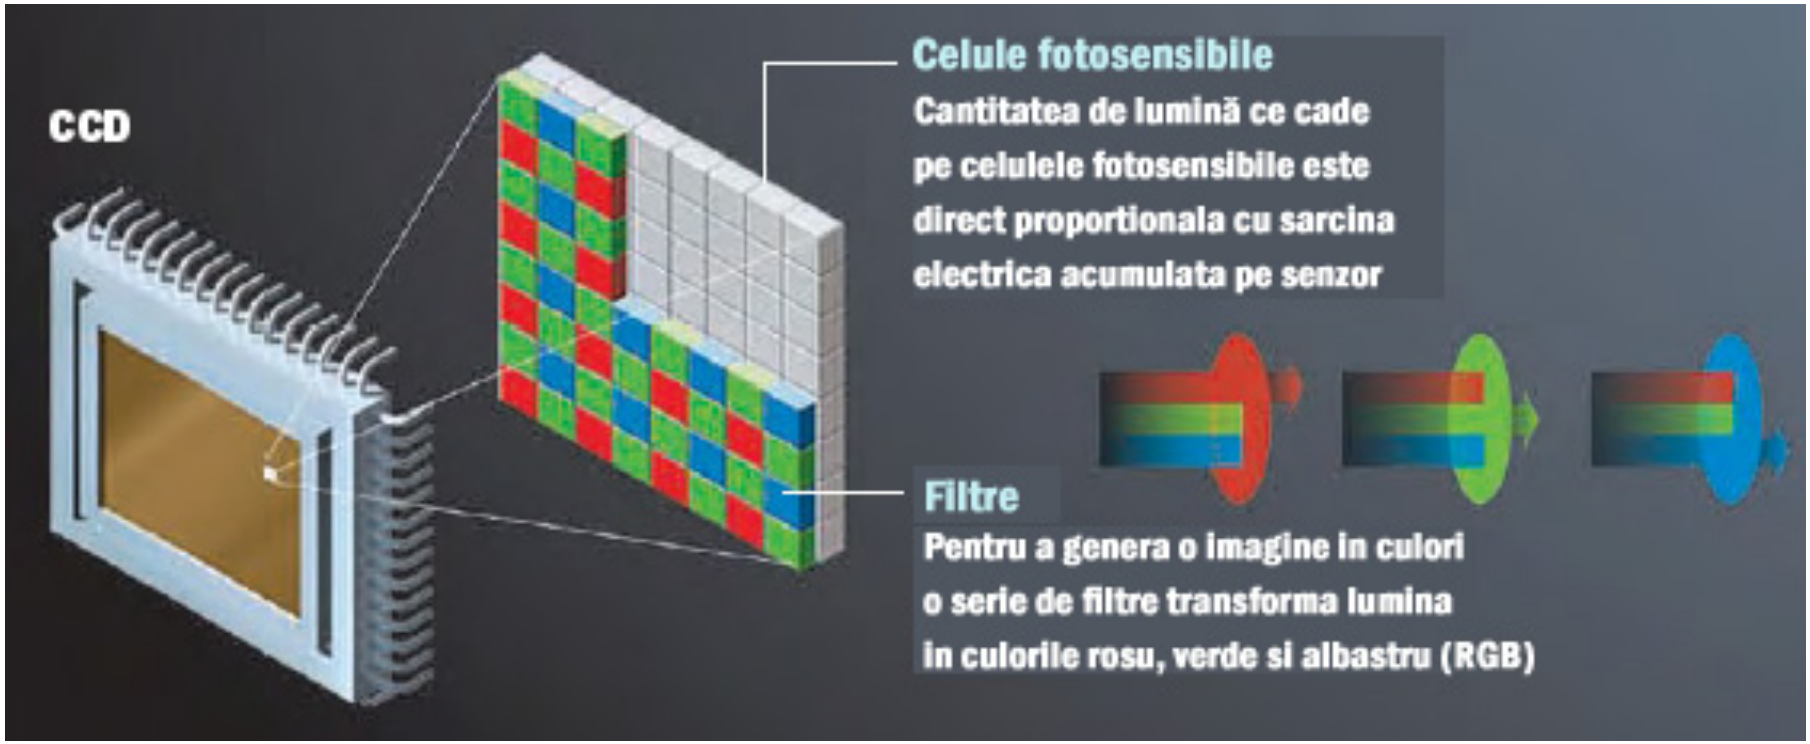

Senzor de imagine Filtru Bayer

Tipuri de imagini digitale

Binare

Grayscale
(tonuri de gri)

Color

Luminozitate	**negru, alb**	**tonuri de gri**	**R G B**
Valori	{**0**,**1**}	{**0**, … , **255**}	{0, …,255}^{3}
Culori	**negru - 0**, **alb - 1**	**negru - 0**, **gri - 128**, **alb - 255**	**(255,0,0)**, **(0,255,0)**, **(0,0,255)**, **(0,0,0)**,**(255,255,255)**, **(255,255,0)**, **(255,125,0)**, **(0,255,255)**, **(255,0,255)**
Memorie/ pixel	1 bit/pixel	8 biți/pixel	24 biți/pixel

RGB2GRAY

Color

Grayscale
(tonuri de gri)

$$gray = 0.2989 * R + 0.5870 * G + 0.1140 * B$$

coeficienți determinați pe
baza percepției vizuale umane

https://en.wikipedia.org/wiki/Color_vision

Imagini privite ca funcții

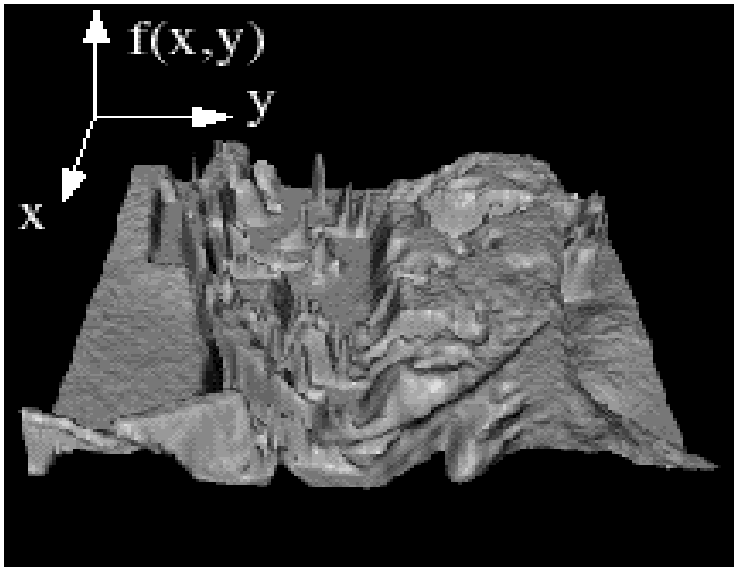

- Imaginea $I : \mathbf{R^2} \rightarrow \mathbf{R}$, $I(x, y)$ - intensitatea la (x,y)
- $I : [\mathrm{a\ b}] \times [\mathrm{c\ d}] \rightarrow [i_{min}\ \ i_{max}]$ (interval + intensitate mărginite)
- Imagini color: $I(x,y) = \begin{bmatrix} r(x,y) \\ g(x,y) \\ b(x,y) \end{bmatrix}$

Slide adaptat după Steve Seitz

Imagini digitale

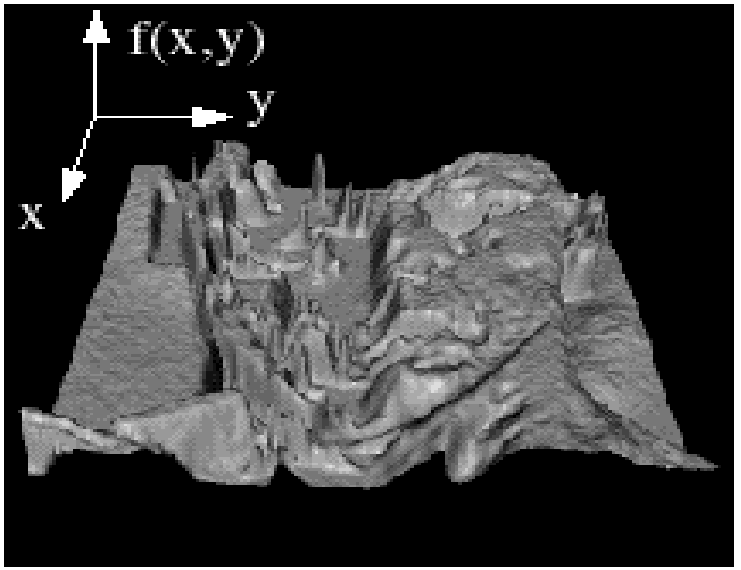

- I - matrice 2D cu valori întregi
- Intensități {0, 1, …, 255}
  - luminozitate 0 = negru
  - luminozitate 255 = alb

y

x

62	79	23	119	120	105	4	0
10	10	9	62	12	78	34	0
10	58	197	46	46	0	0	48
176	135	5	188	191	68	0	49
2	1	1	29	26	37	0	77
0	89	144	147	187	102	62	208
255	252	0	166	123	62	0	31
166	63	127	17	1	0	99	30

Slide adaptat după Steve Seitz

Tema 1

- termen limită pentru prima temă: duminică, 8 noiembrie!

- e nevoie de cunoștințe de procesarea imaginilor + programare (orice limbaj de programare este admis) ☺

Imagini mozaic

imagine de referință

+

colectie de imagini (piese)
de dimensiuni reduse
28 x 40 pixeli

+

algoritm codat de voi

=

imagine mozaic

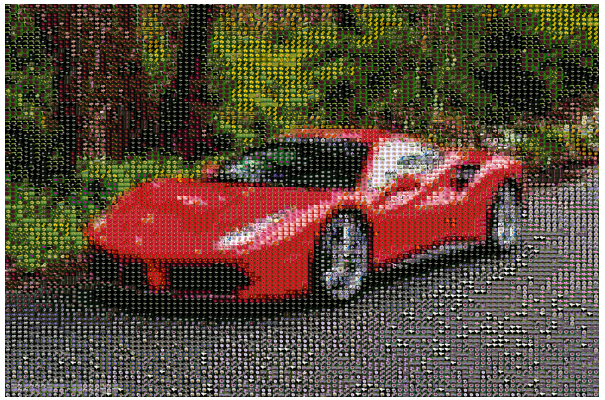

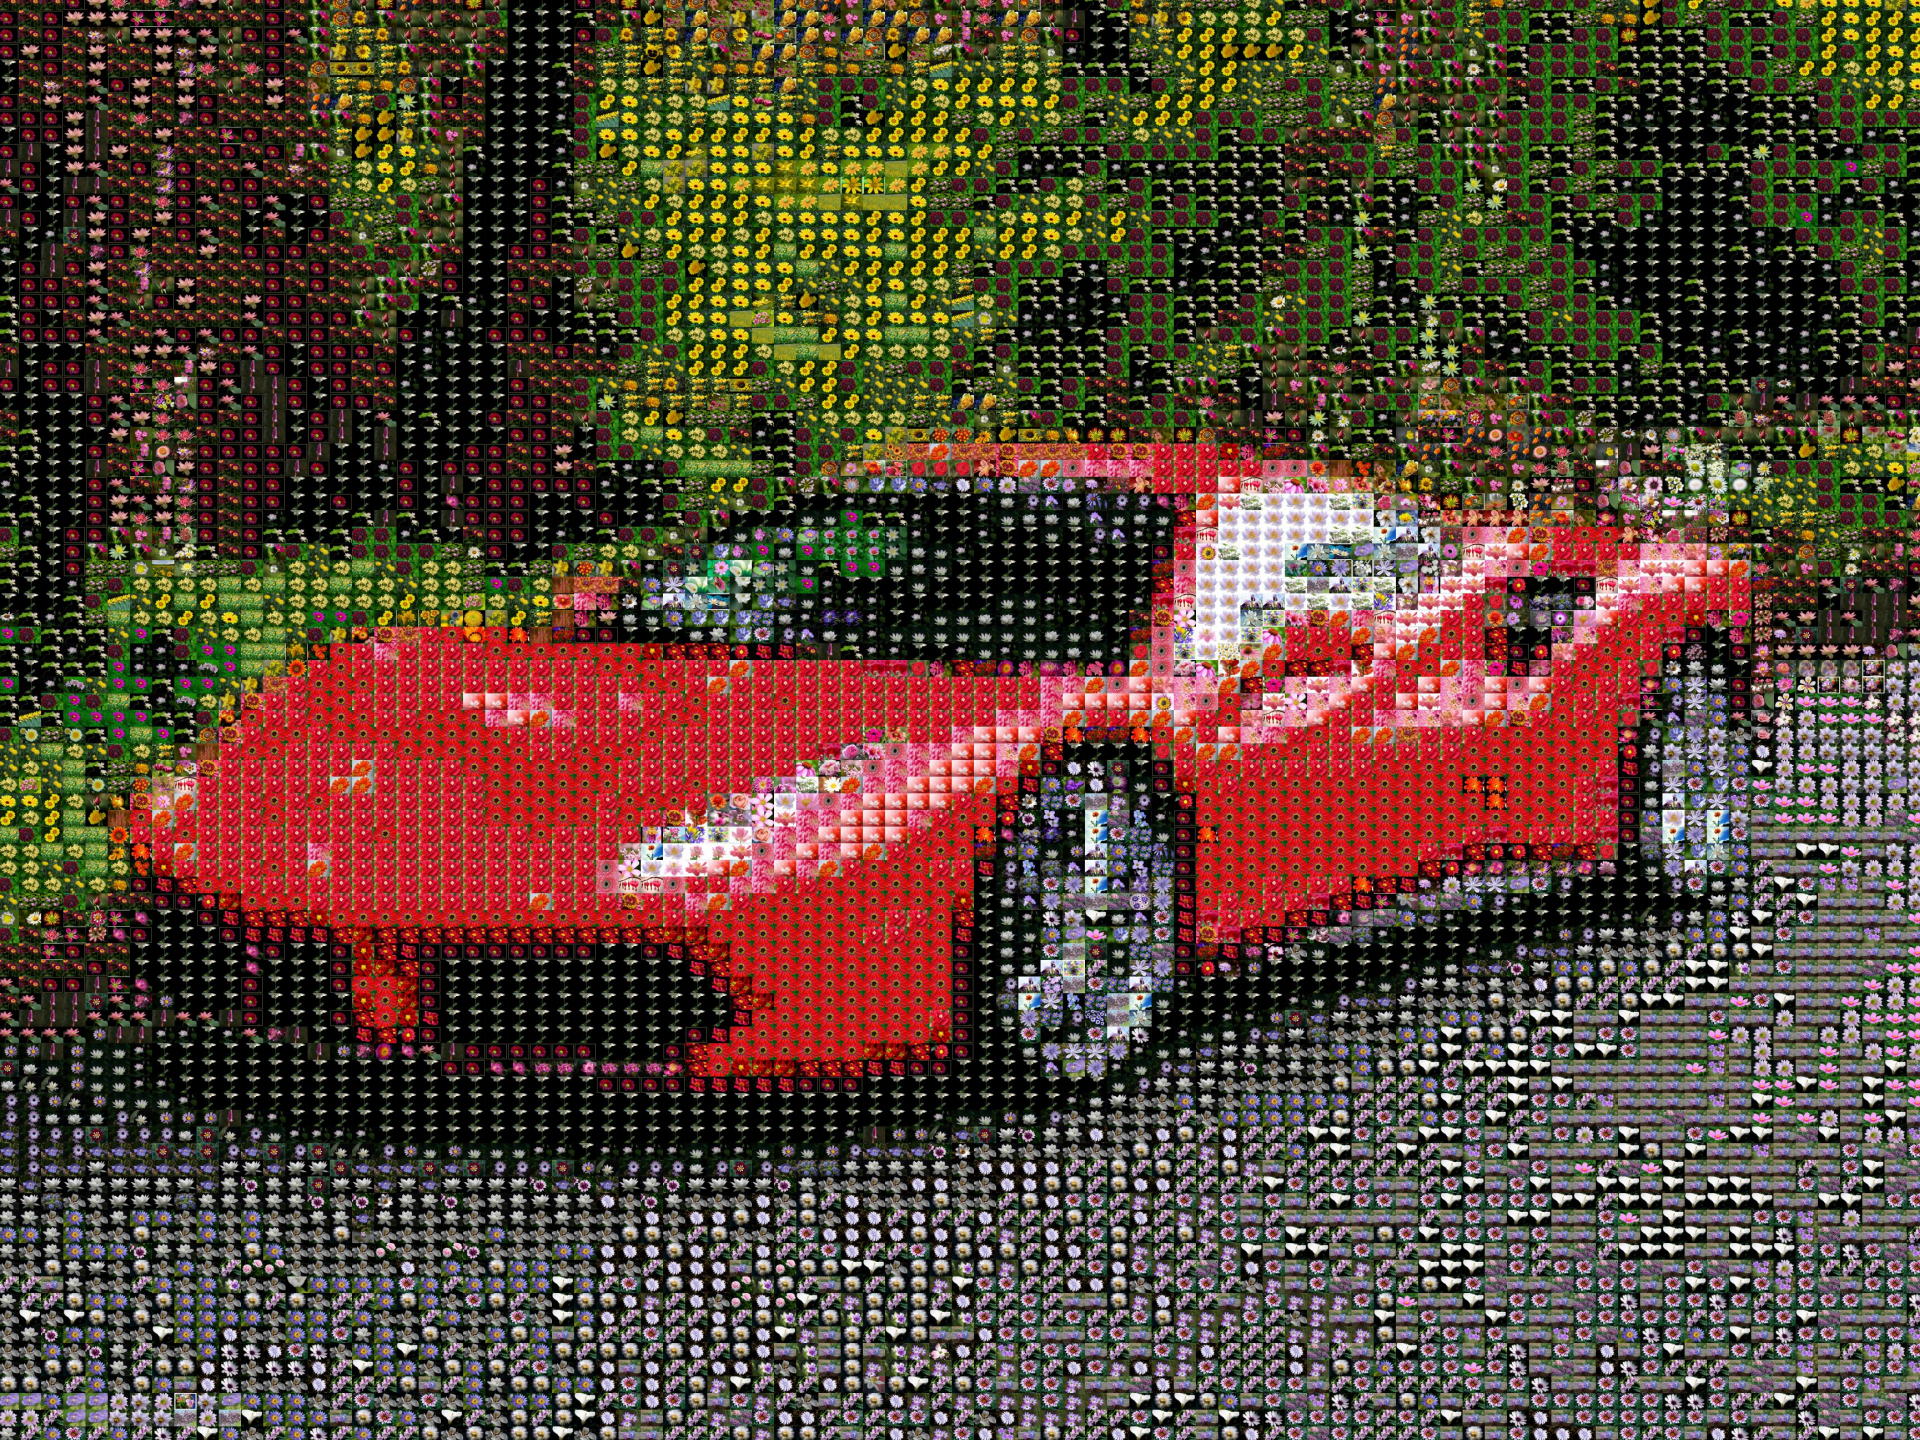

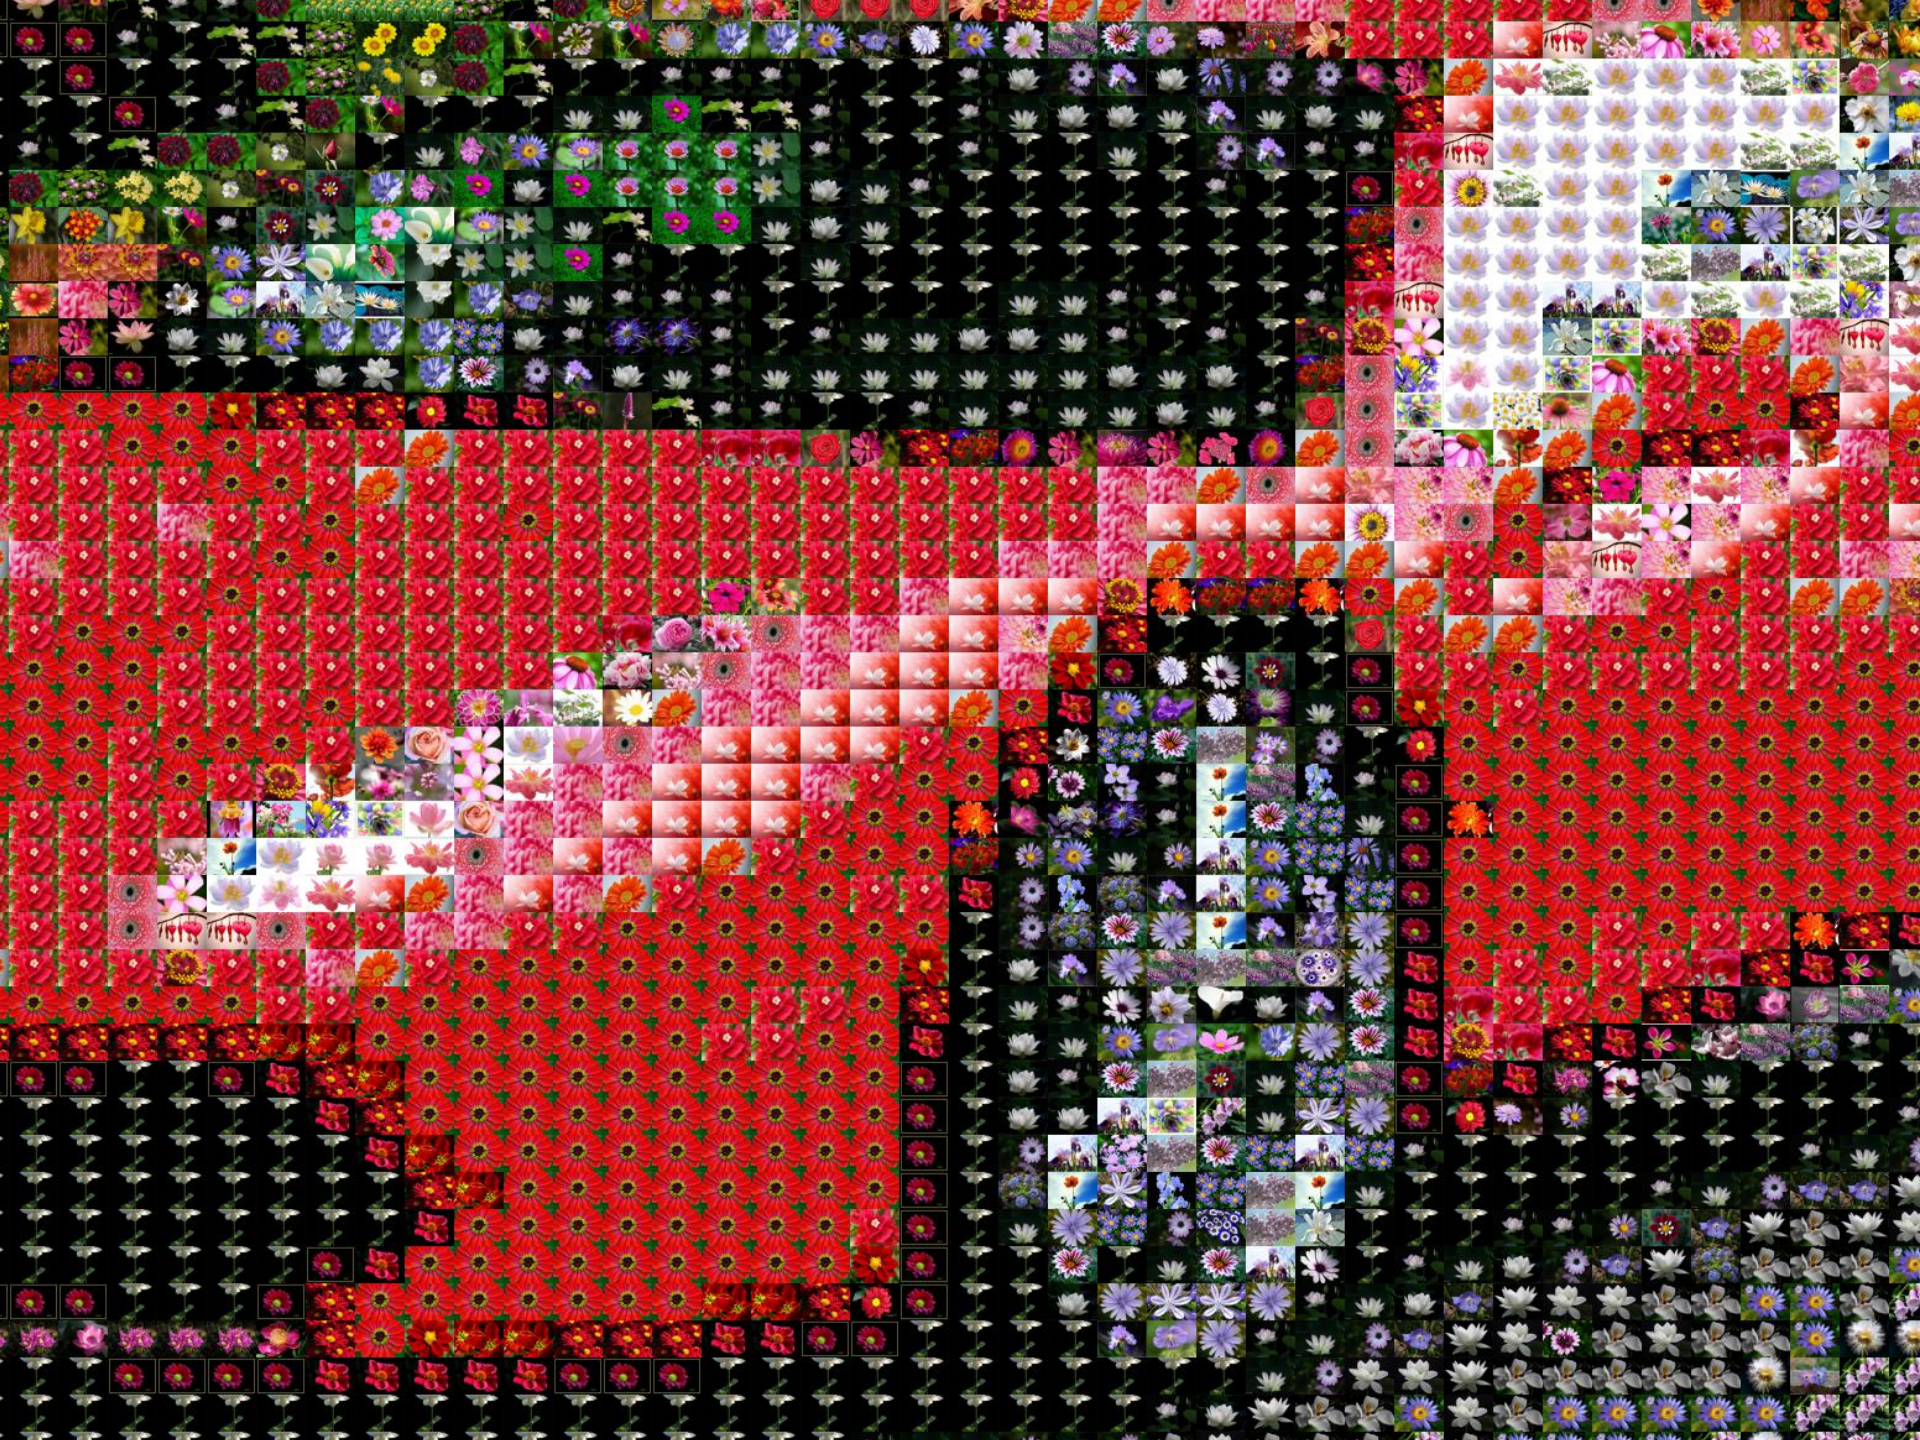

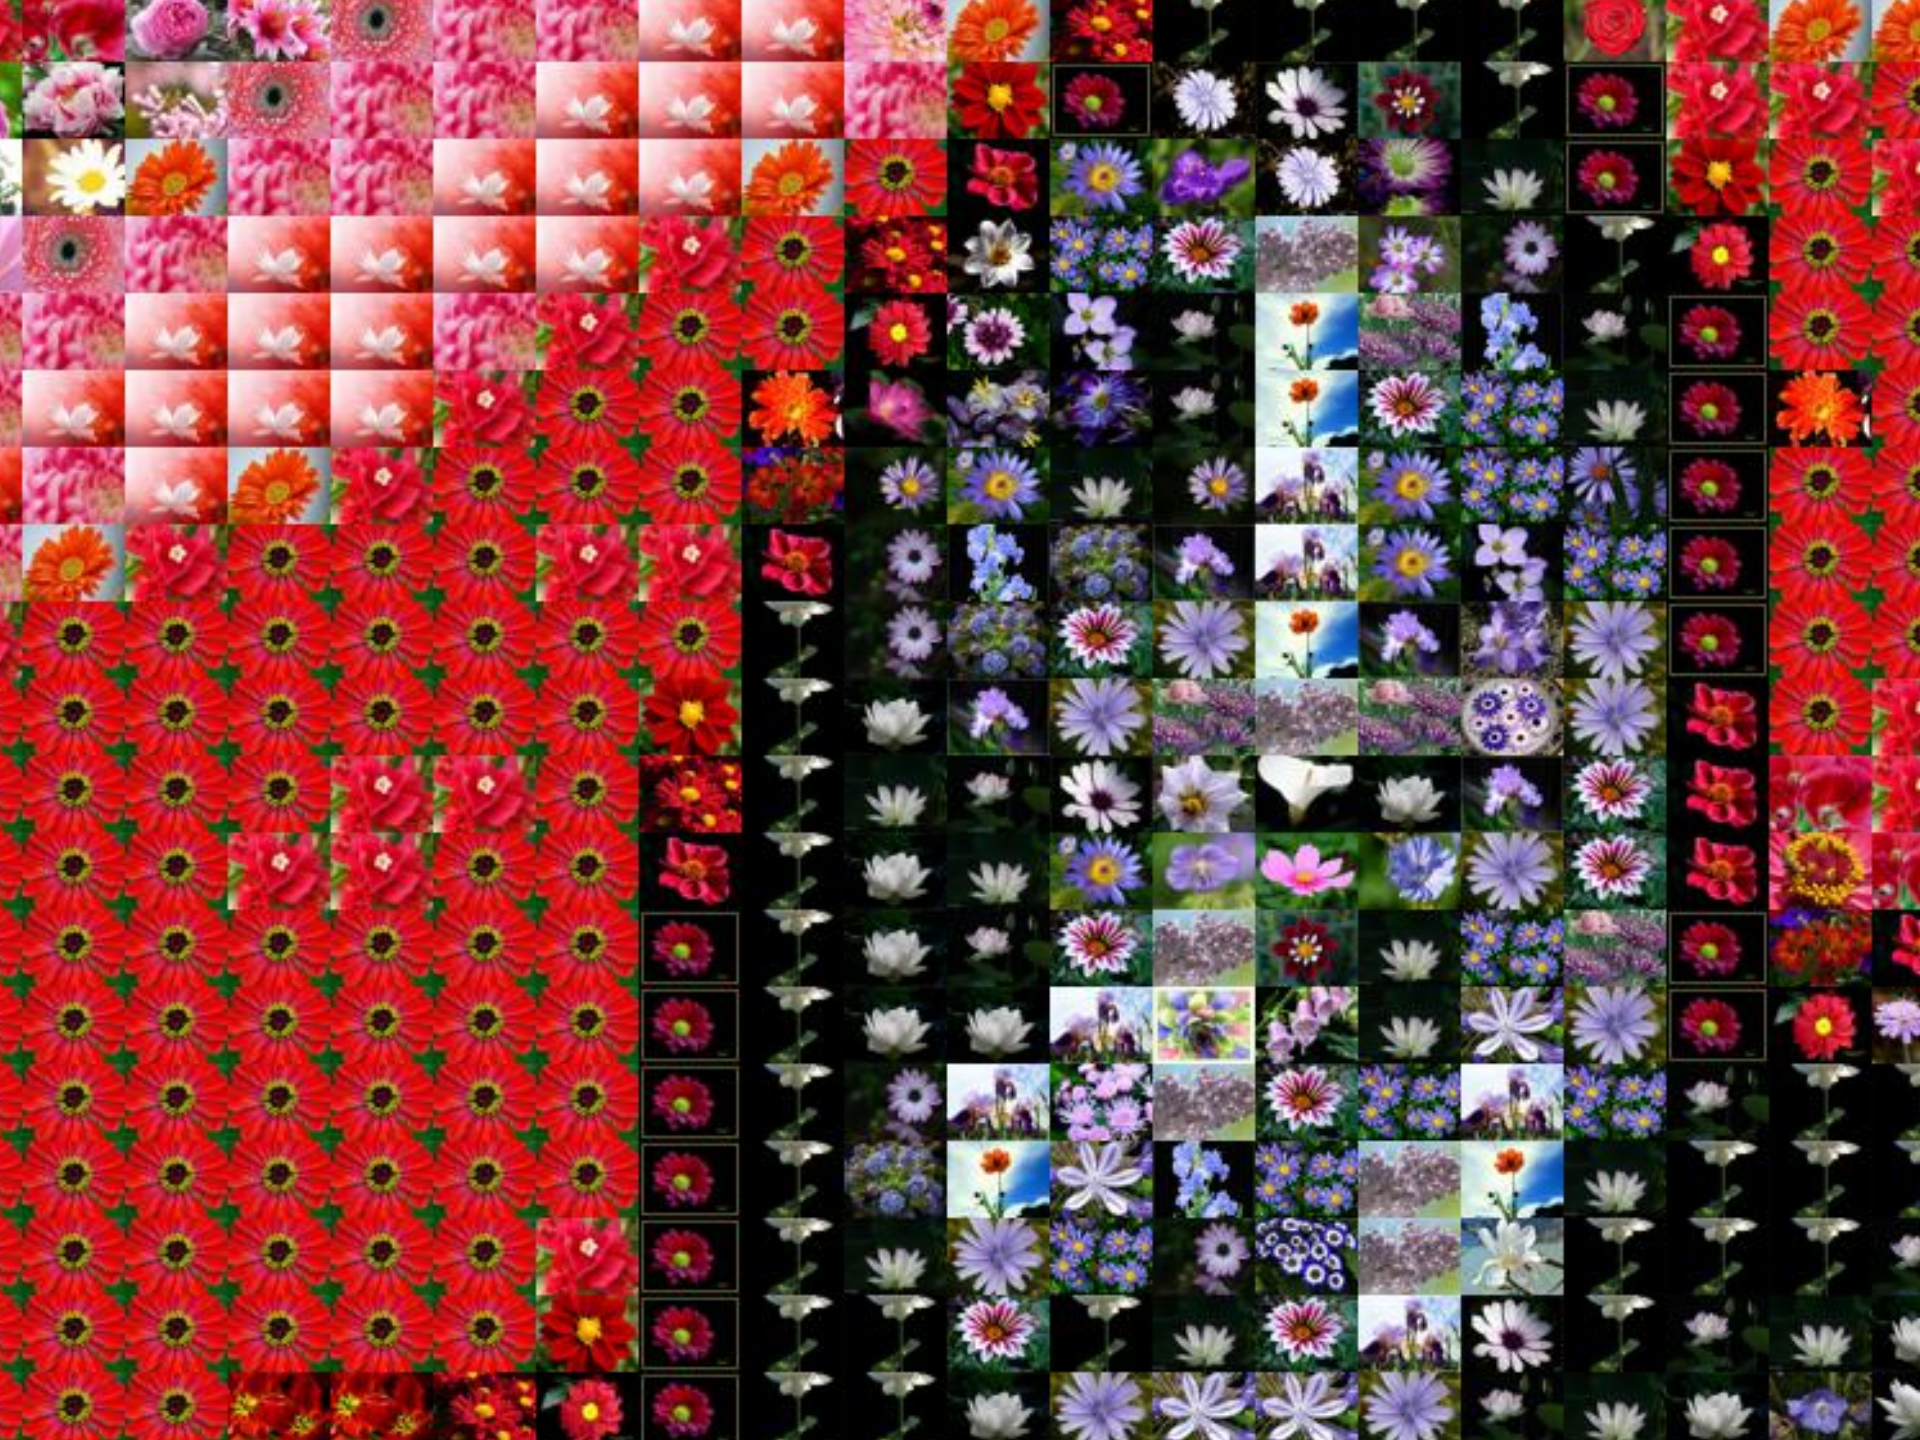

Algoritm

Input:

1. imagine de referință

2. colecție de imagini (piese)
   500 de piese a 28 x 40 pixeli

3. număr piese în lățime ale mozaicului (implicit = 100)

1	2		100

Algoritm – varianta 1

Pași:

1. determină înălțimea mozaicului:
   - păstrează proporția (aspect ratio) imaginii de referință inițiale
   - multiplu de înălțimea unei piese

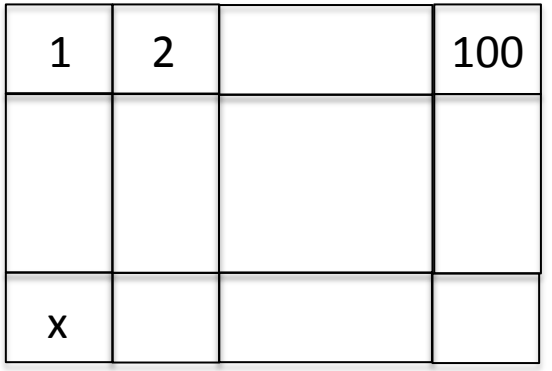

2. adaugă piese în mozaic pe un grid (caroiaj): aplică un criteriu pentru a selecta piesa care se potrivește cel mai bine într-o poziție:
   - aleator (alegem piesele întâmplător)
   - culoarea medie cea mai apropiată (cea mai mica distanță euclidiană)

Criterii

- aleator: alegem piesele la întâmplare, considerând că orice piesă la fel de bună ca cealaltă în orice poziție

imagine de referinta

imagine mozaic

Criterii

- culoarea medie cea mai apropiată:
  - calculăm culoarea medie a pixelilor din blocul de înlocuit din imaginea de referință redimensionată;
  - culoarea medie este un triplet (r_{medie}, g_{medie}, b_{medie}) pentru imagini color sau un scalar i_{medie} pentru imagini gri;
  - calculăm culoarea medie a pixelilor din fiecare piesă;
  - calculăm cea mai apropiată (distanța euclidiană cea mai mică) culoare medie a unui piese de culoarea medie a blocului;
  - înlocuim blocul cu piesa aleasă.

Criterii

- culoarea medie cea mai apropiată

imagine de referinta

imagine mozaic

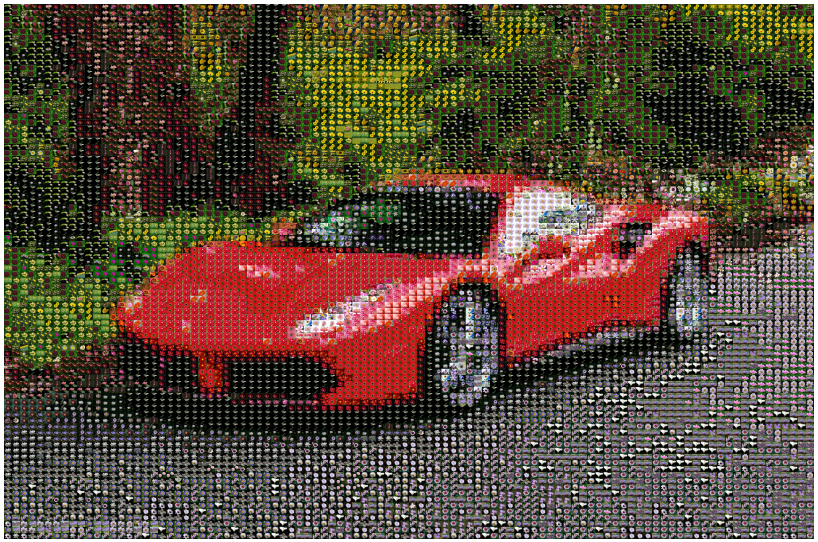

Criterii

- culoarea medie cea mai apropiată

imagine de referinta

imagine mozaic

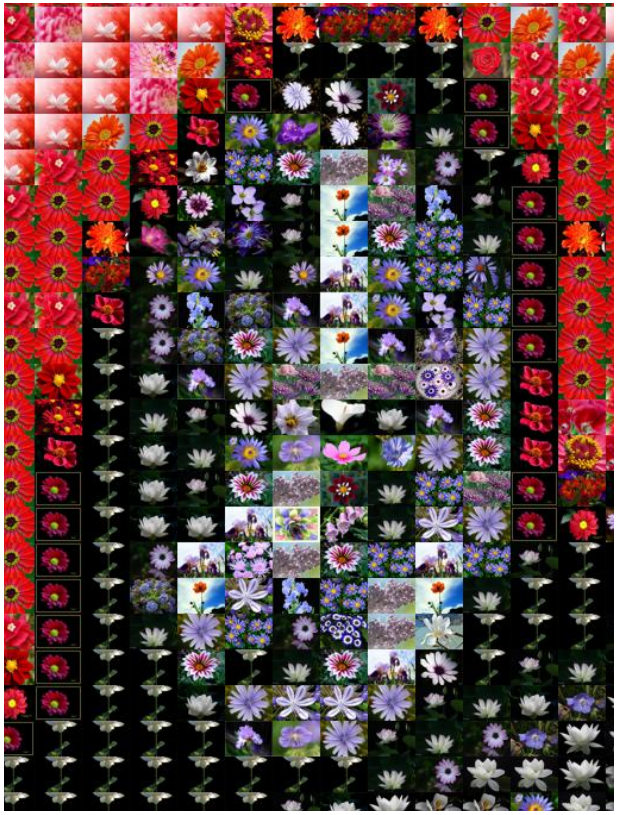

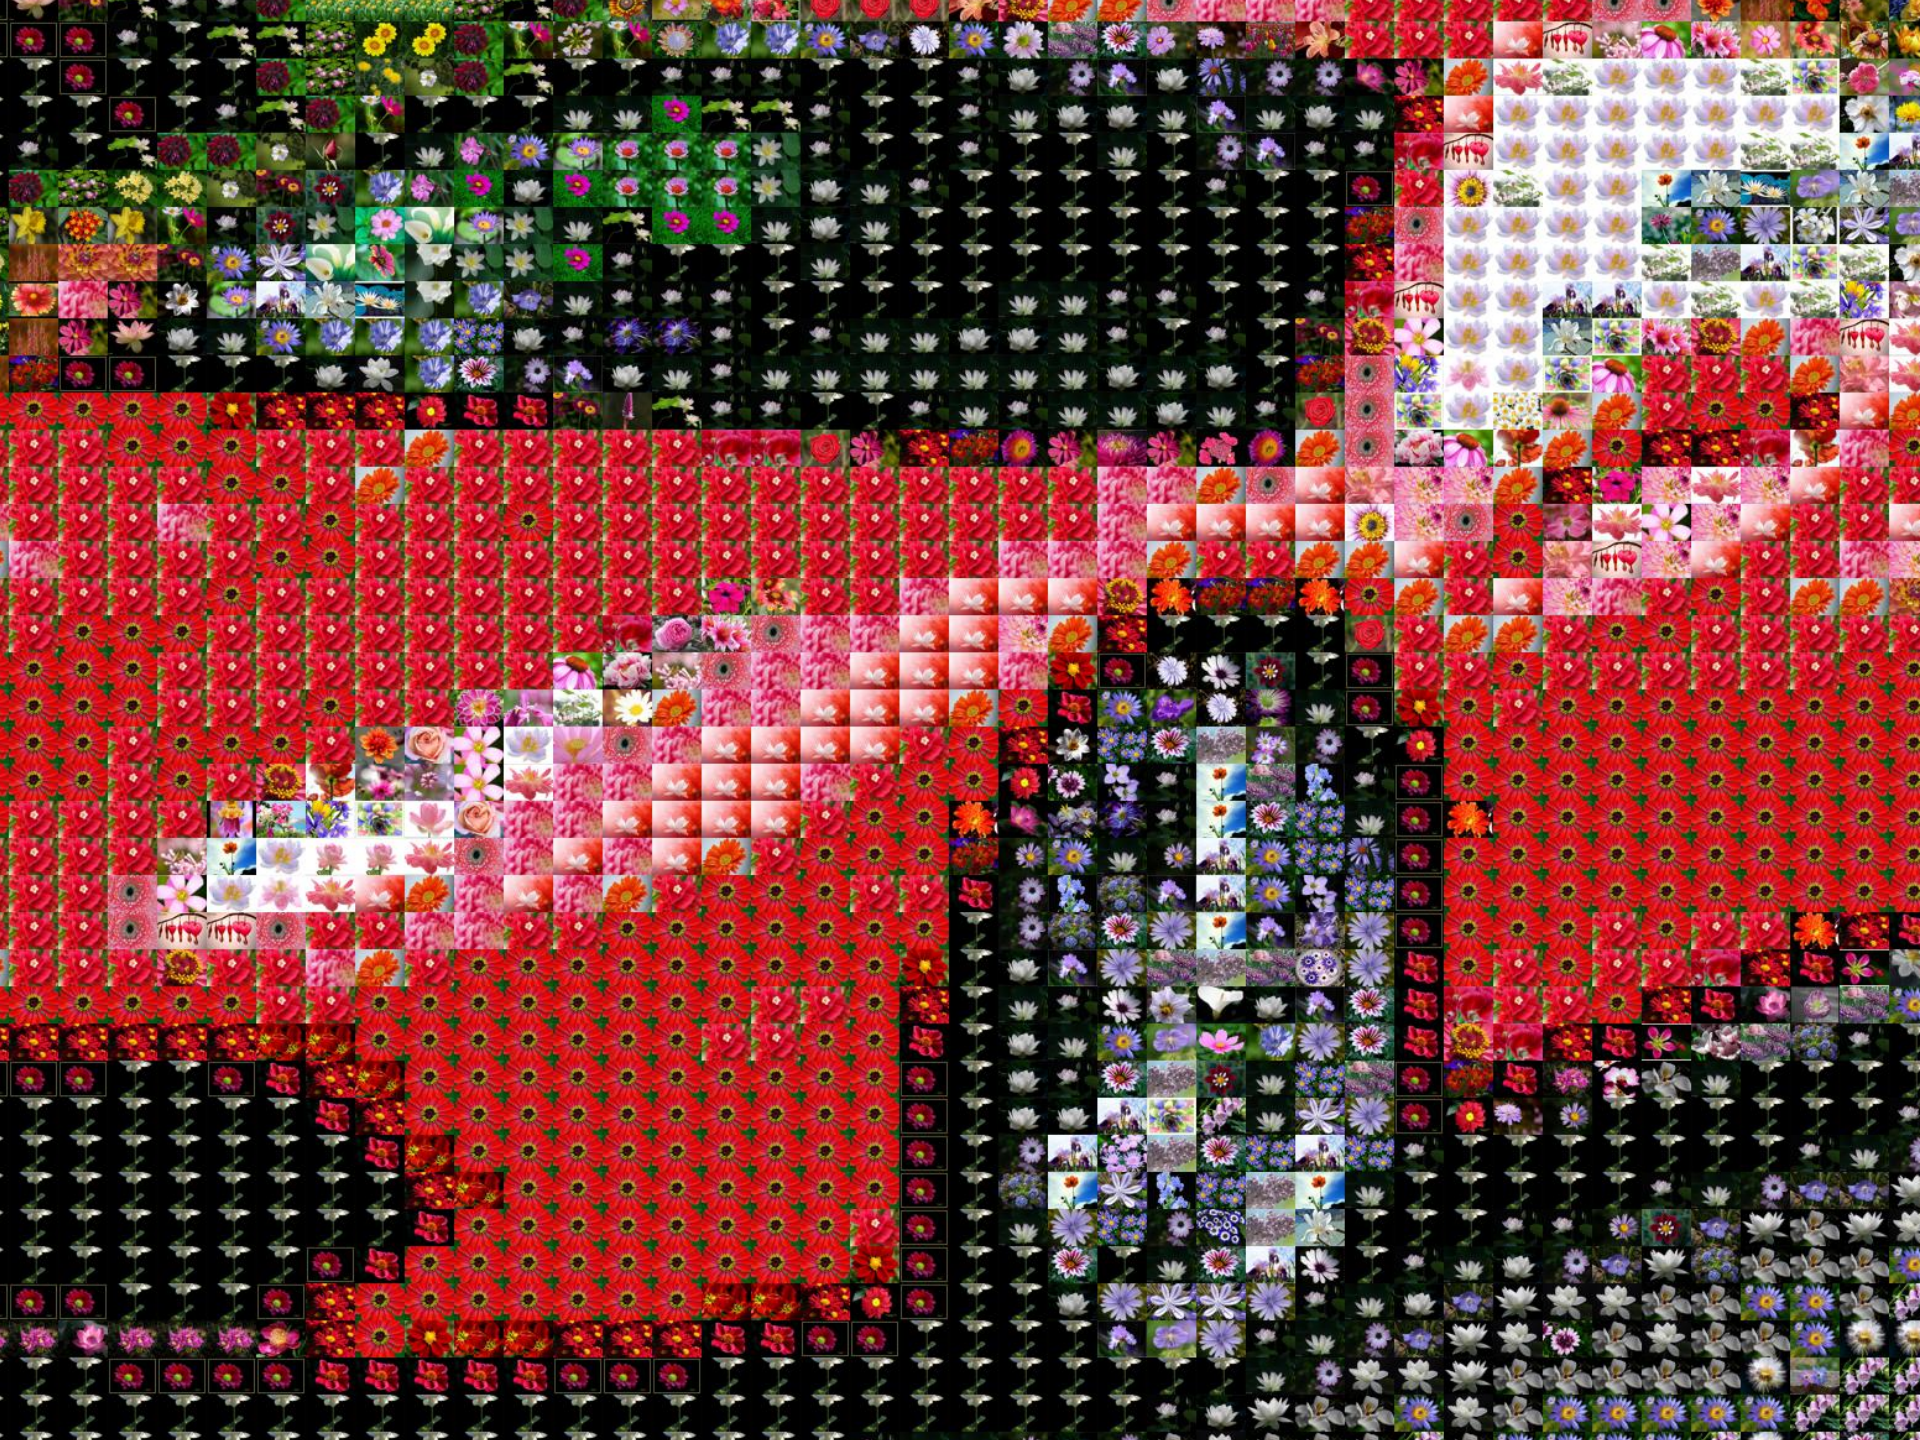

Vecini – piese diferite (conectivitate – 4)

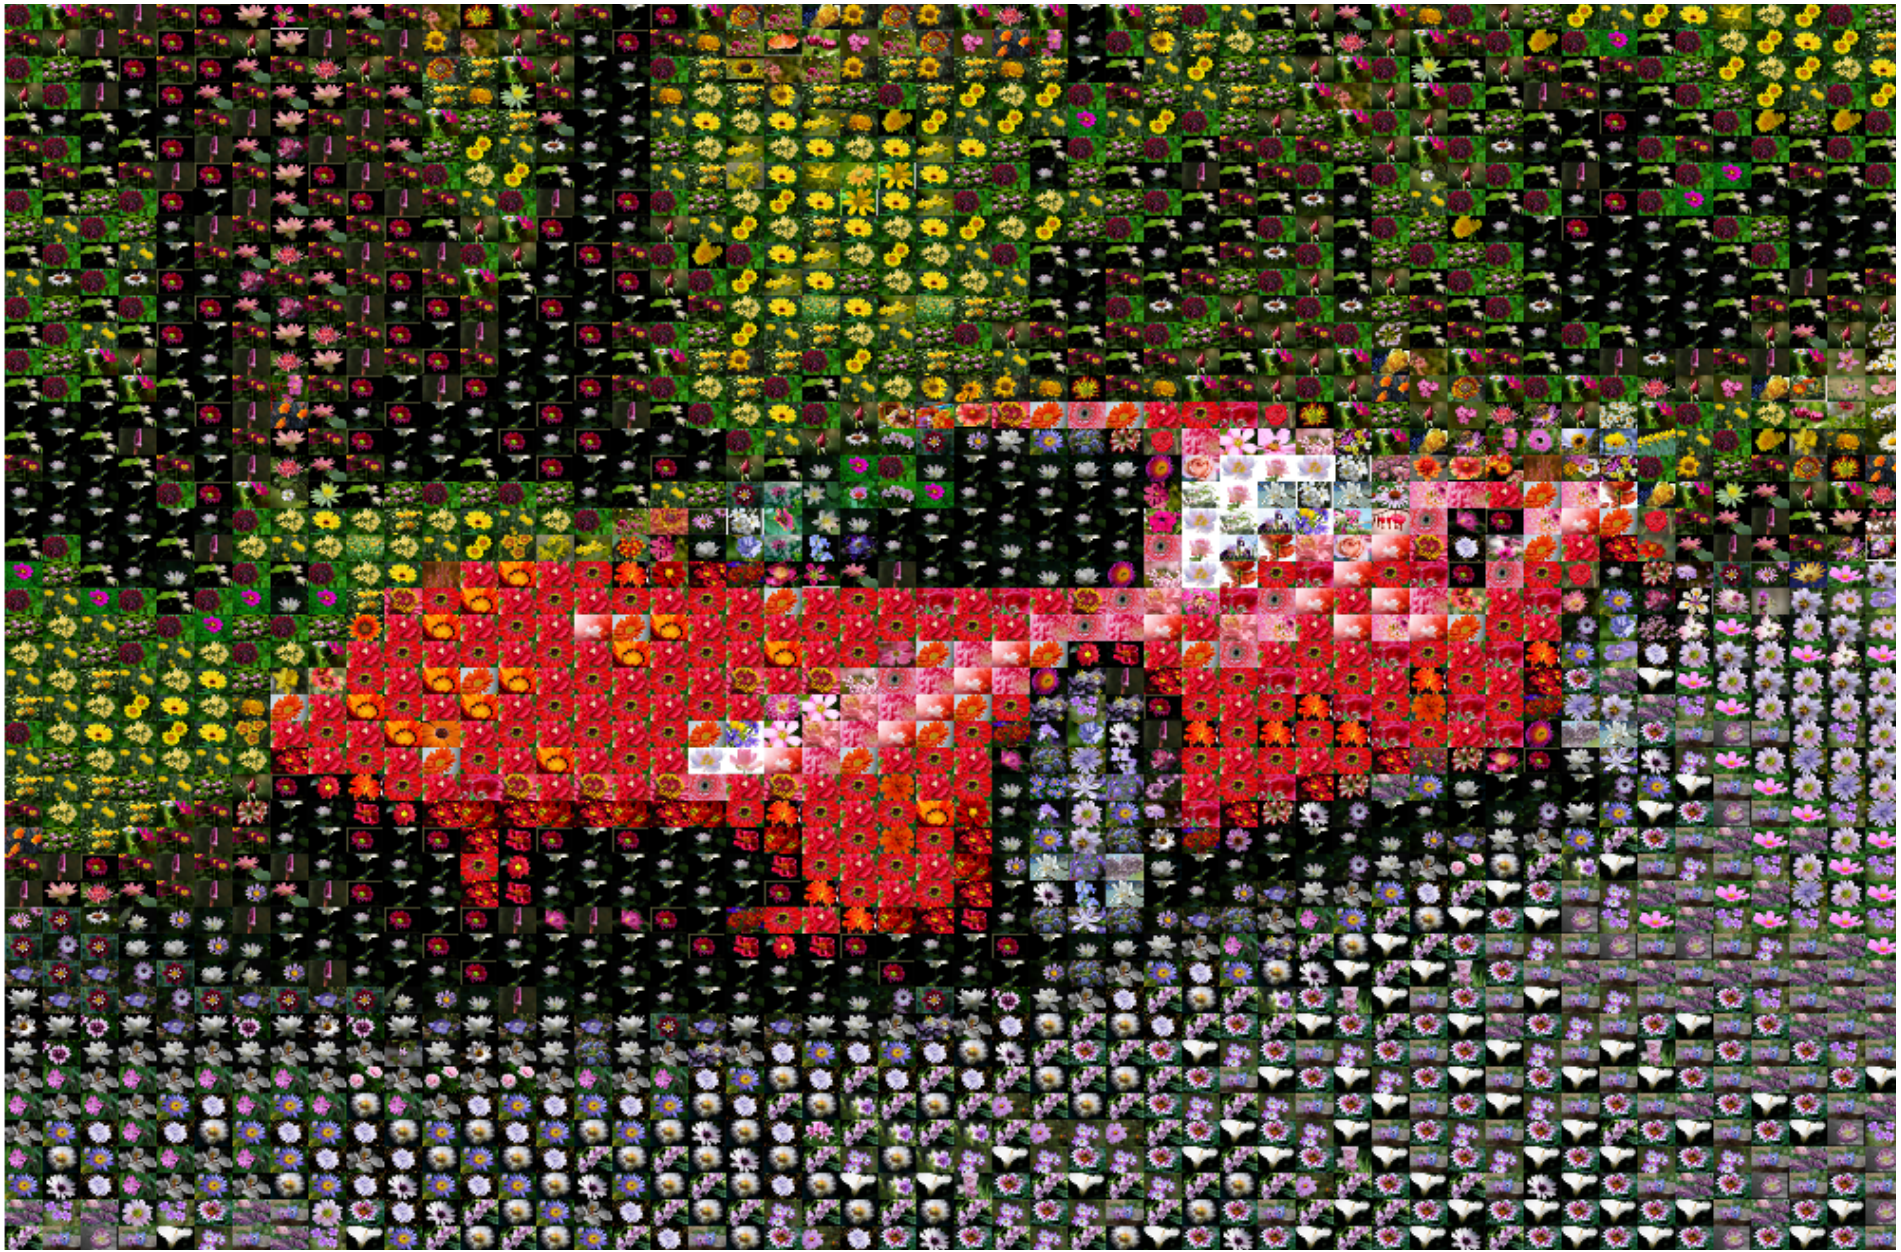

Vecini – piese diferite (conectivitate – 4)

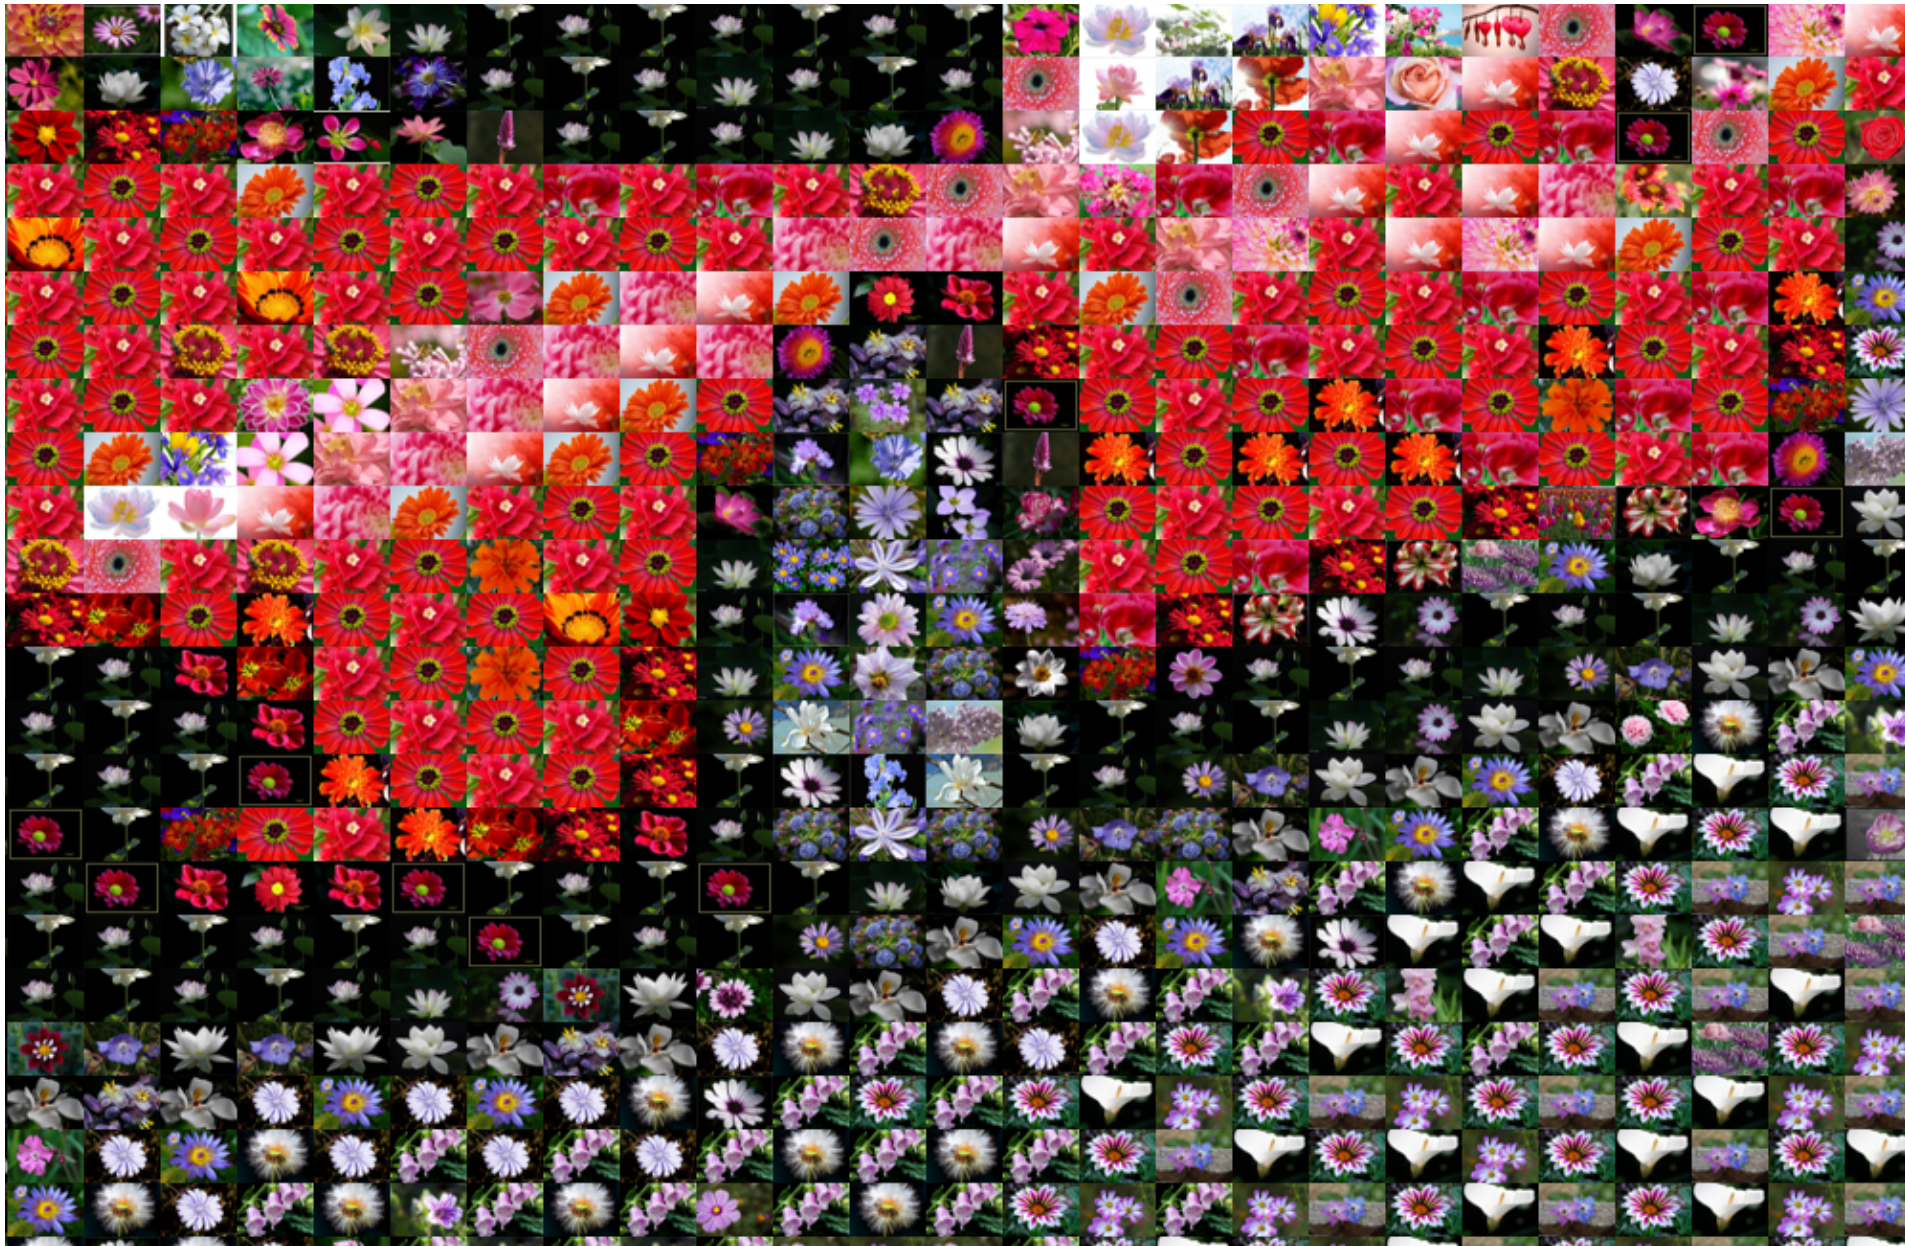

Piese hexagonale

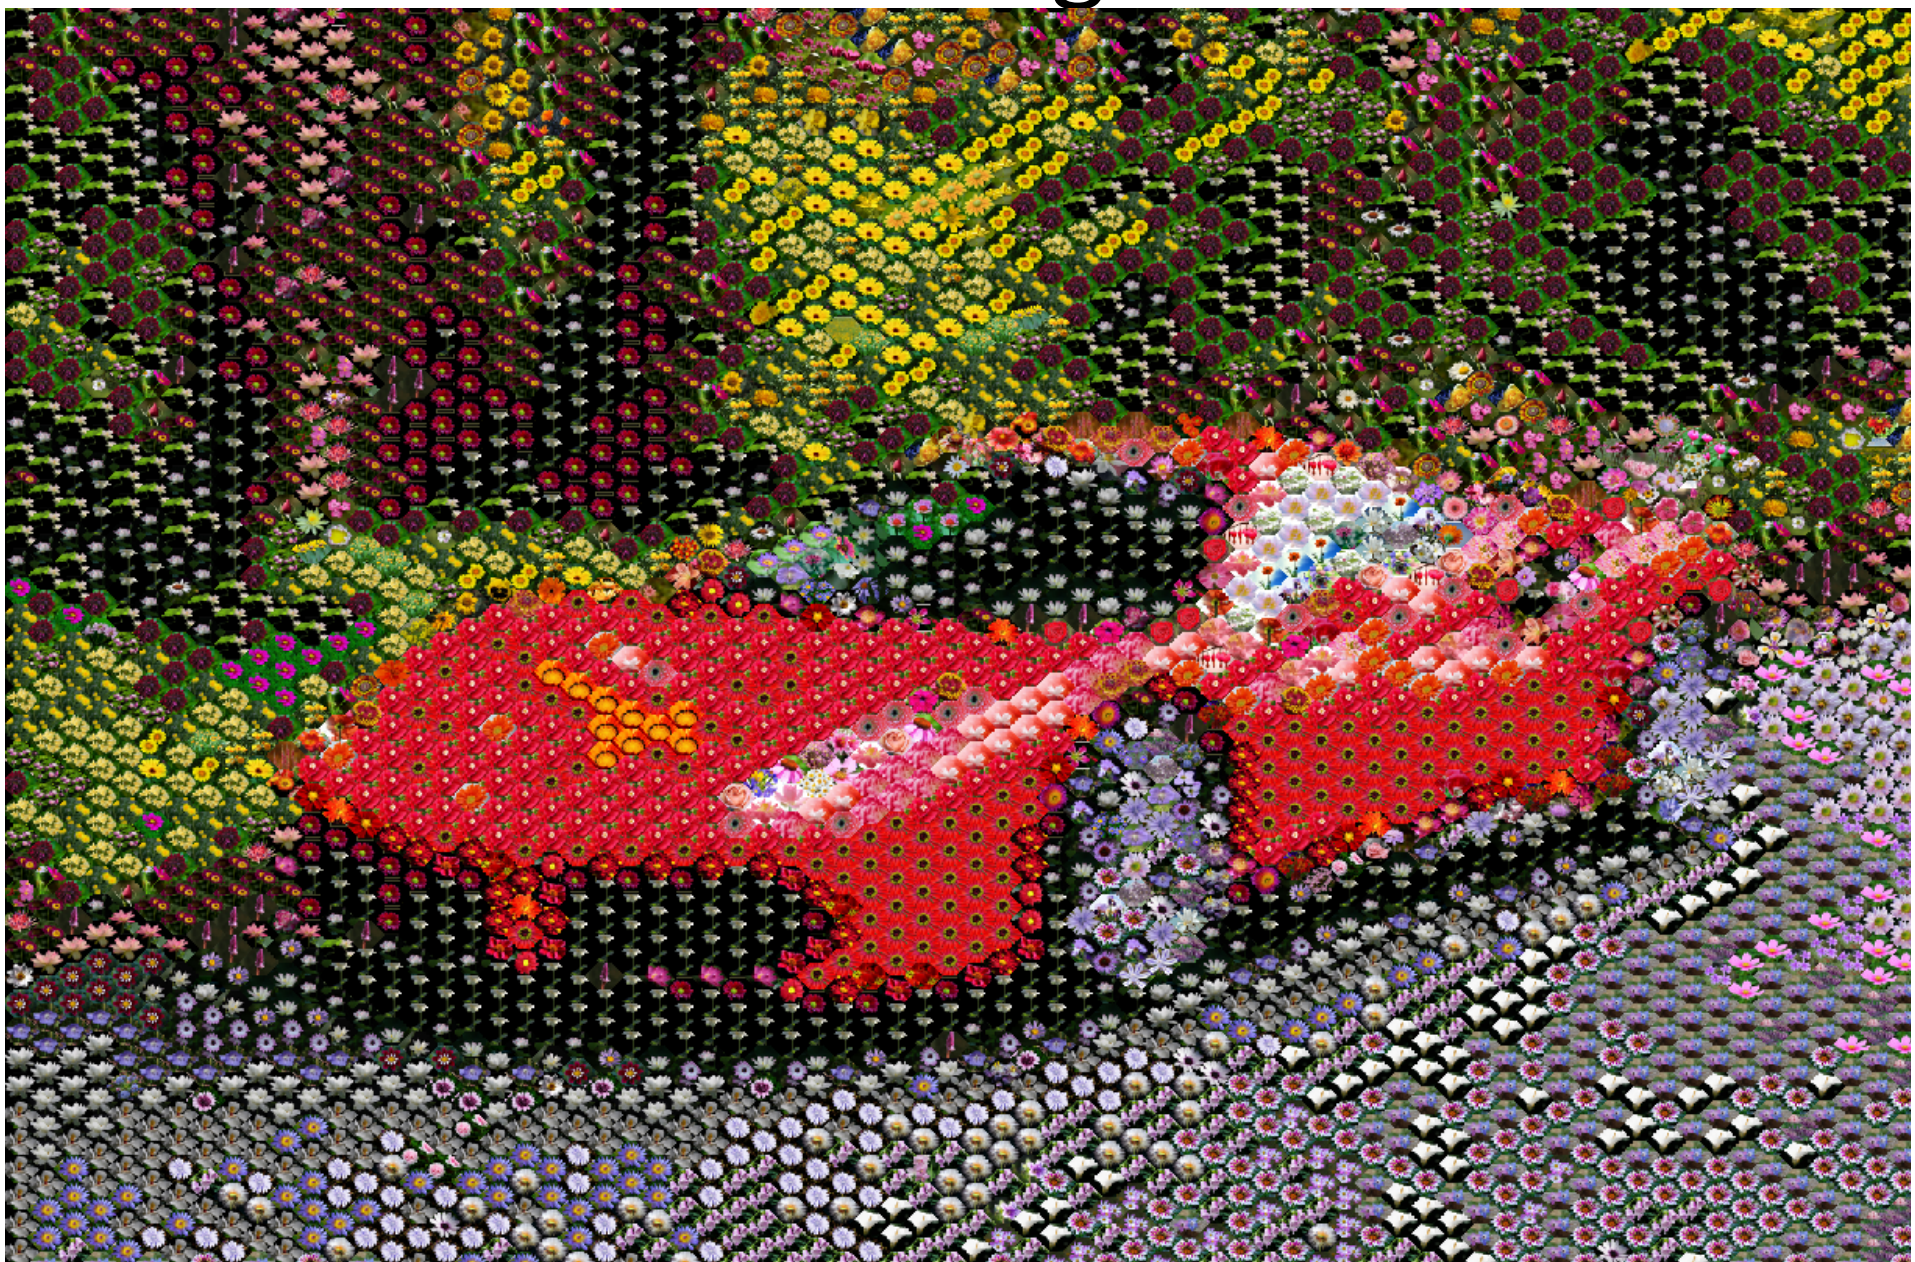

Piese hexagonale

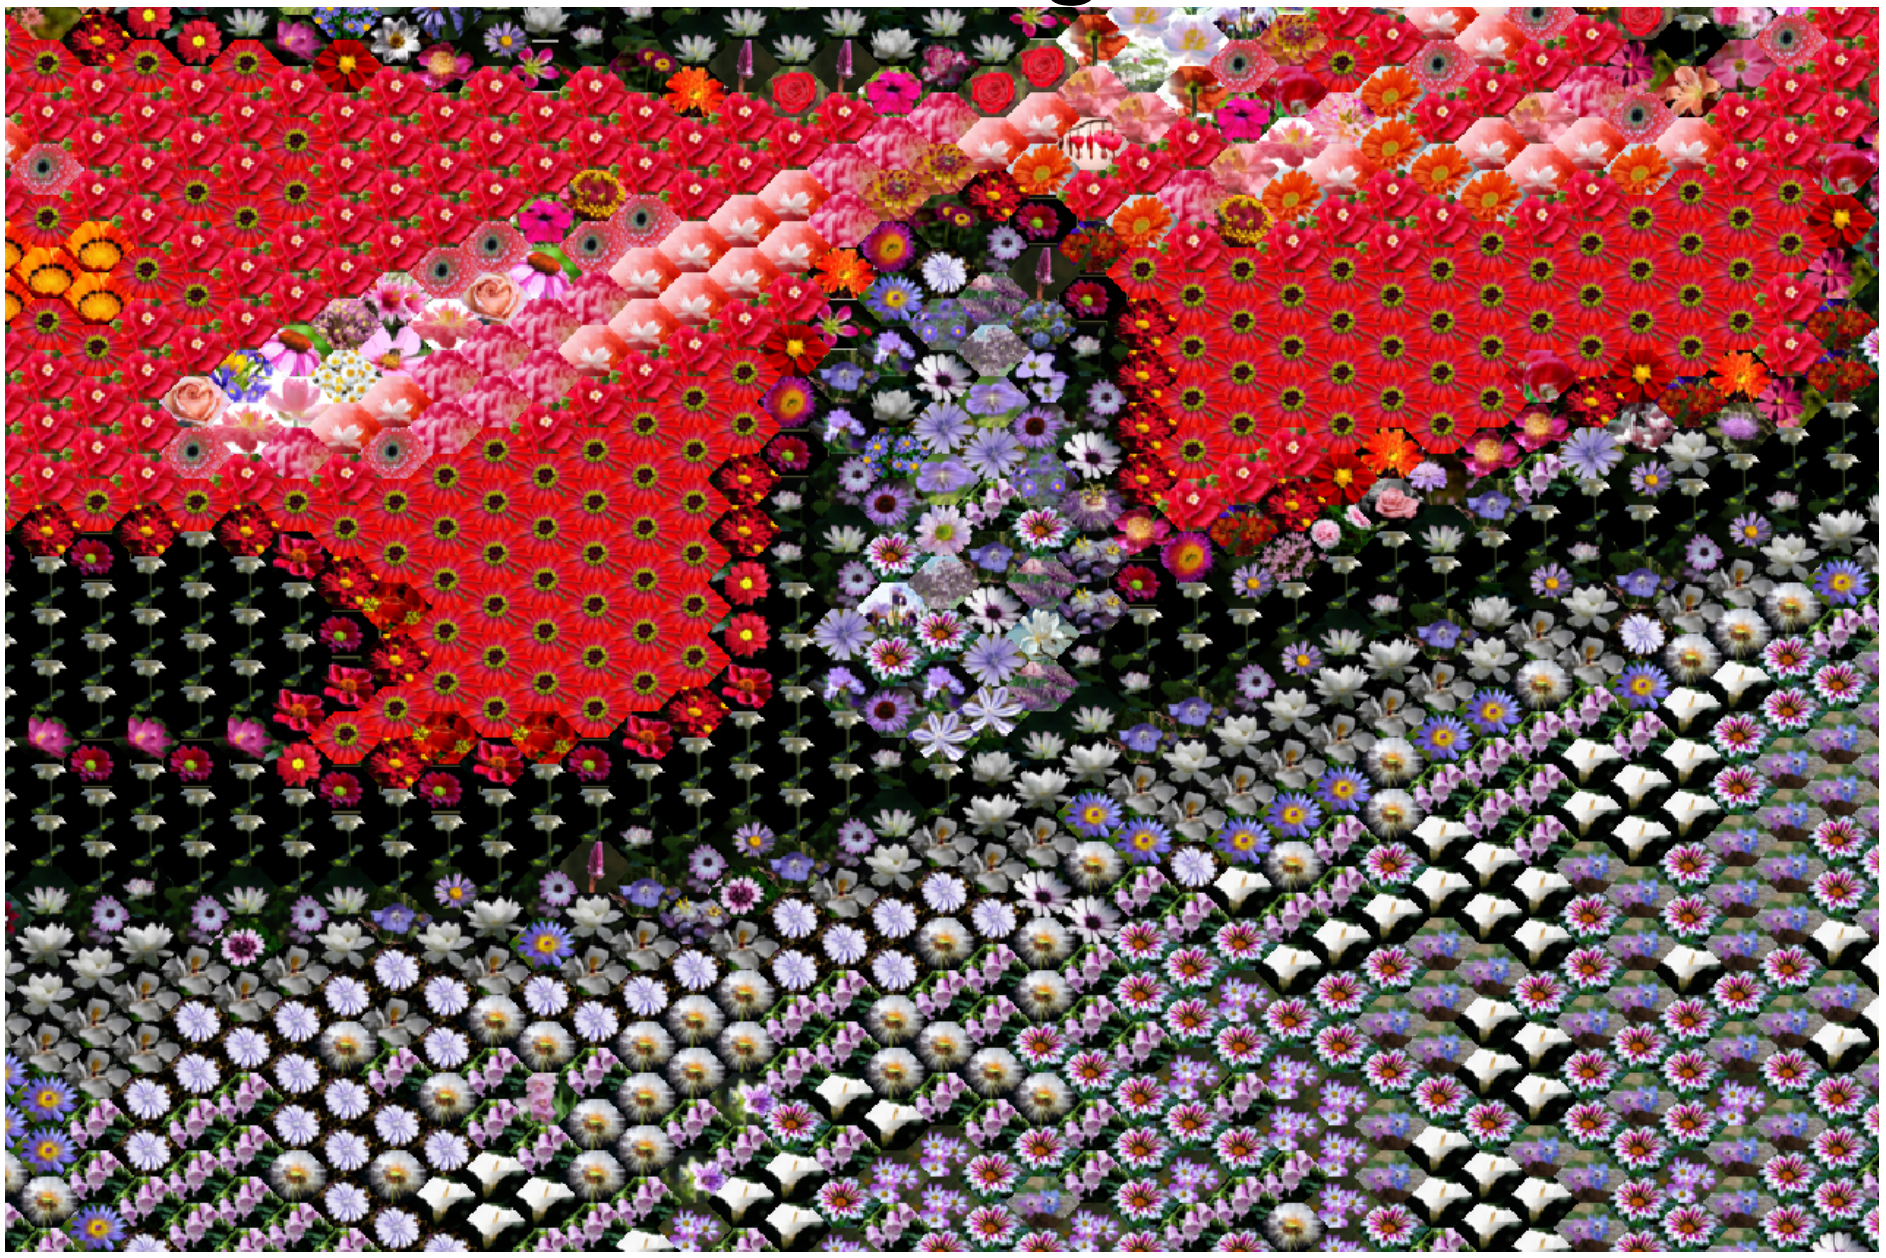

Piese hexagonale

Piese hexagonale

Piese inițială

Mască (valori de 0 și 1)

Piesă hexagonală

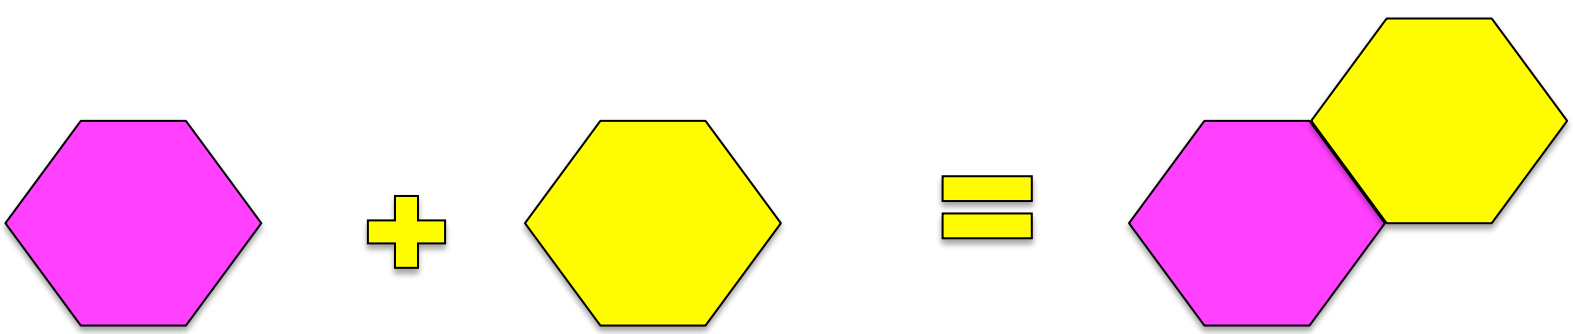

Mozaic cu piese hexagonale

Mozaic cu piese hexagonale

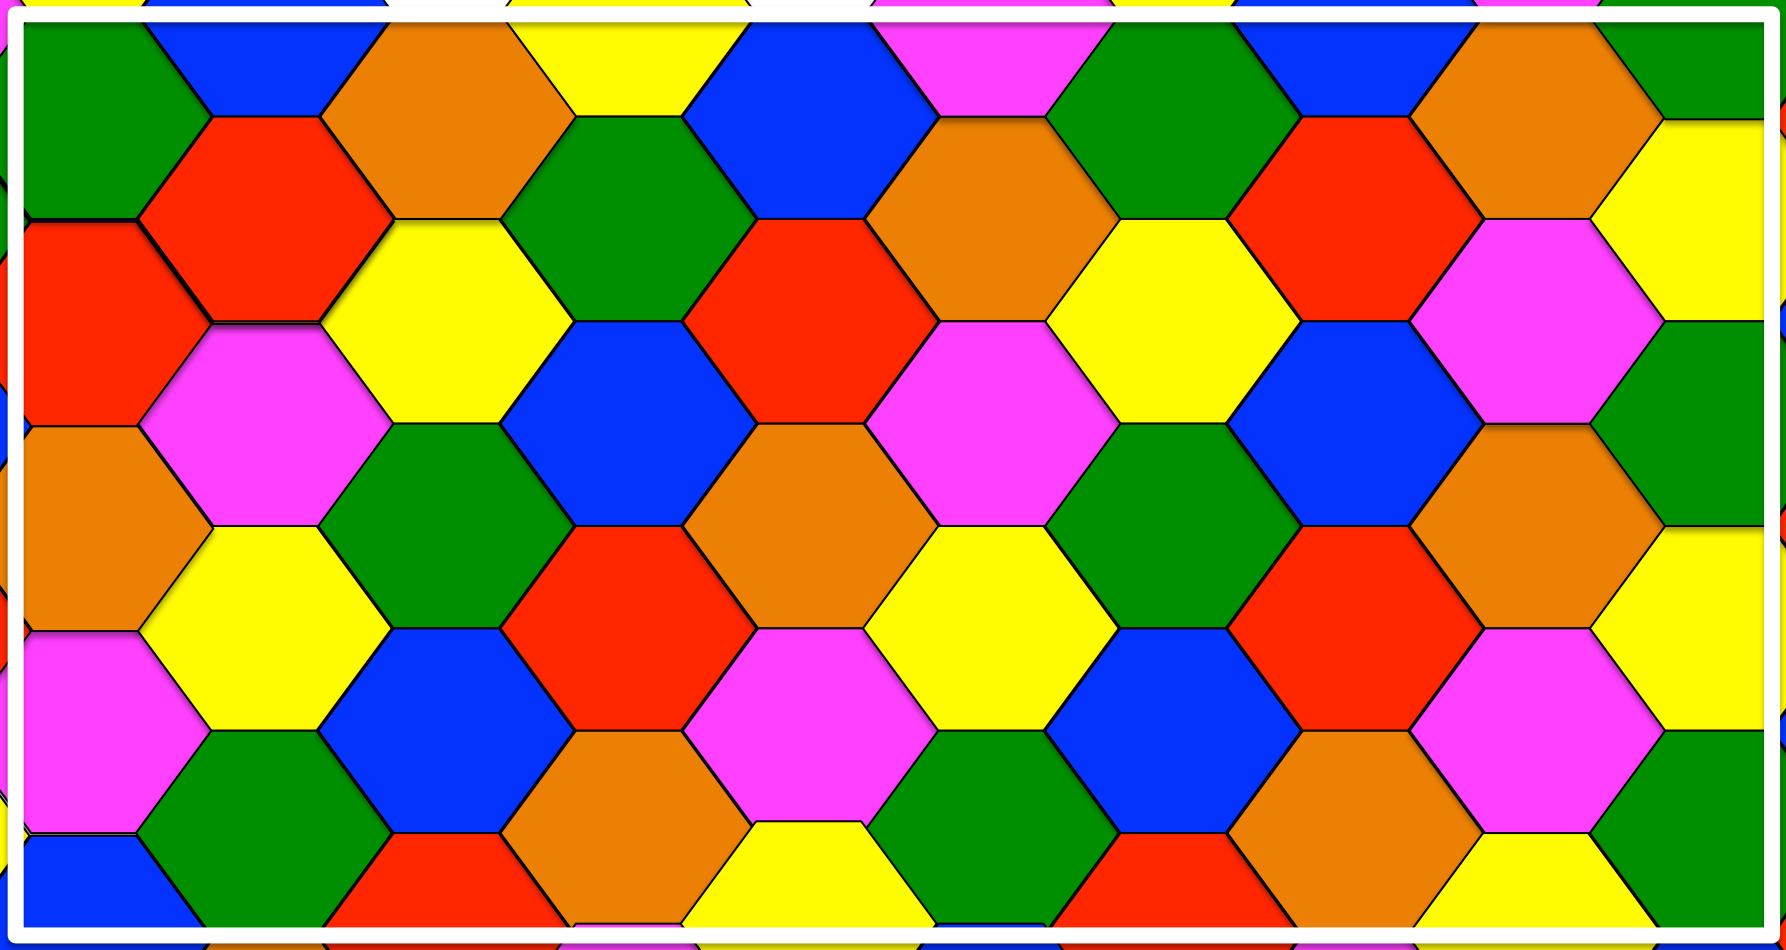

Mozaic cu piese hexagonale

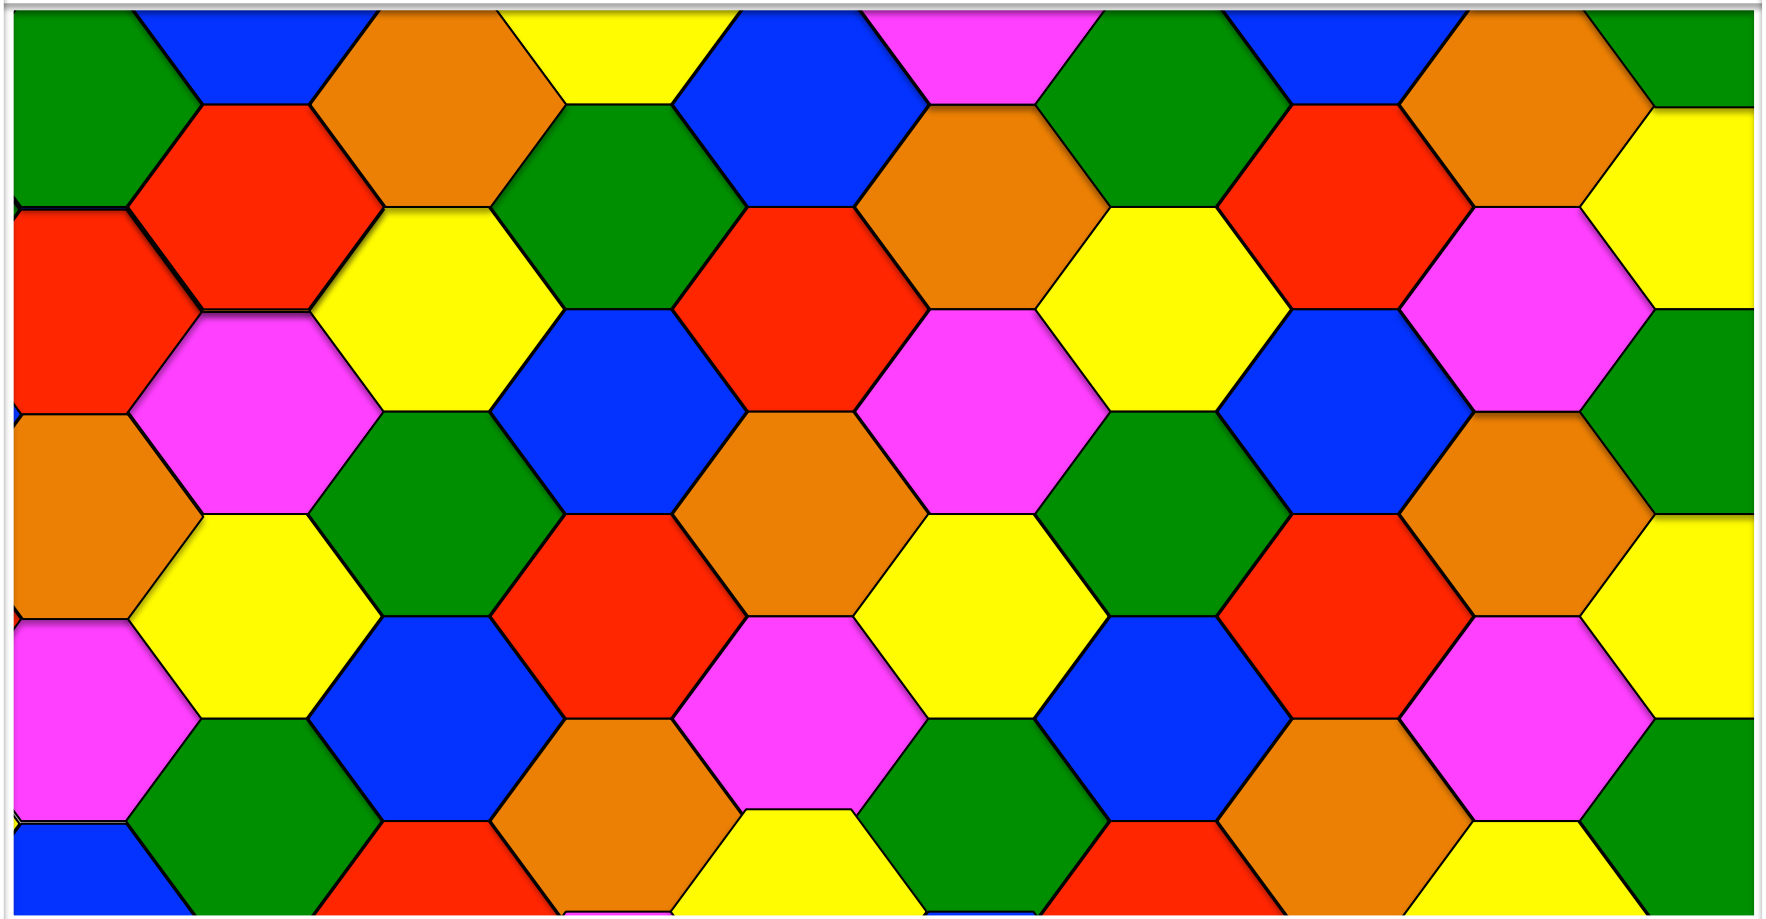

Algoritm – varianta 2

Pași:

1. determină înălțimea mozaicului:
   - păstrează proporția (aspect ratio) imaginii de referință inițiale
   - multiplu de înălțimea unei piese

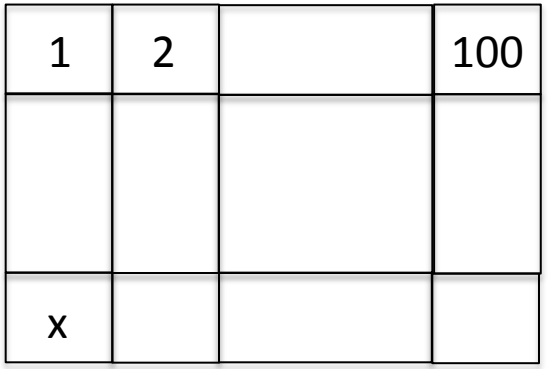

2. adaugă piese în mozaic în poziții aleatoare:
   aplică un criteriu pentru a selecta piesa care se potrivește cel mai bine într-o pozitie:
   - aleator (alegem piesele întâmplător)
   - culoarea medie cea mai apropiată (cea mai mica distanță euclidiană)

Algoritm – varianta 2

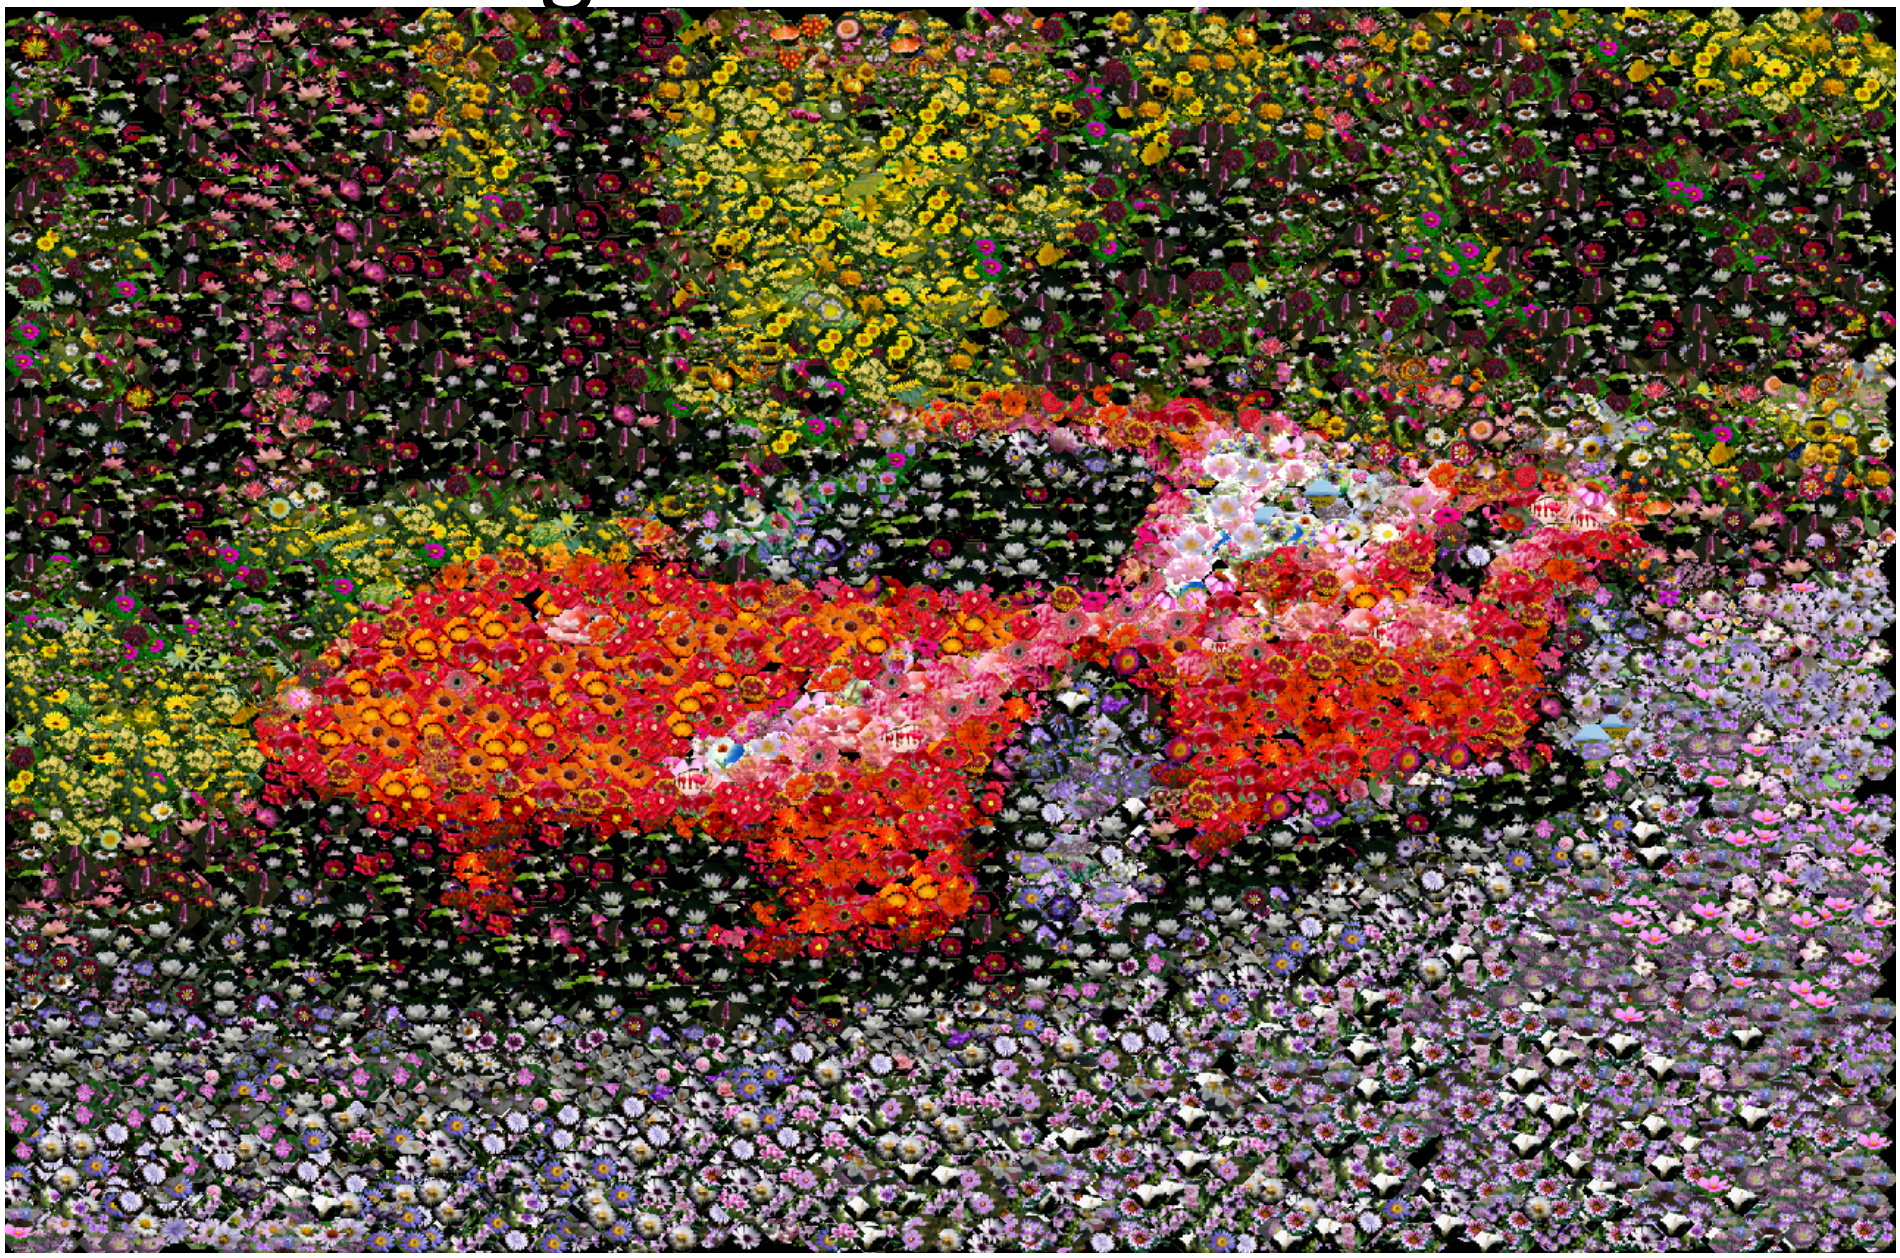

Algoritm – varianta 2

Filtrarea imaginilor

Exemple de filtrare

Filtru de blurare

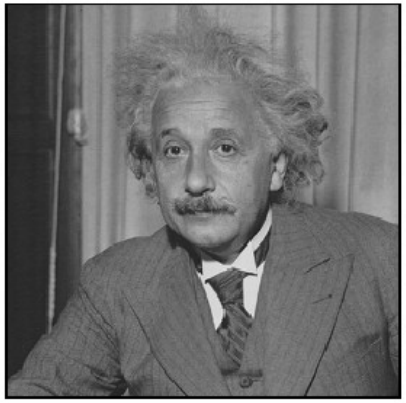

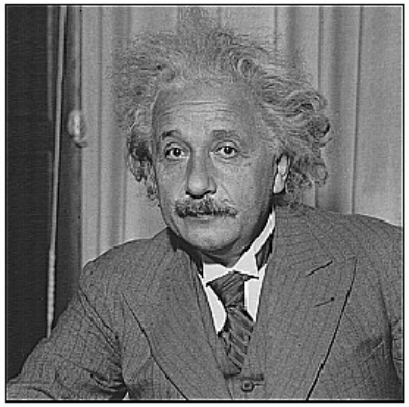

Filtru de accentuare

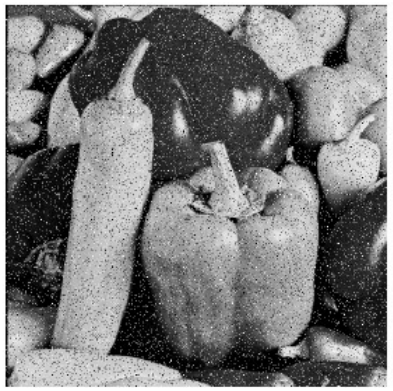

Filtru pentru eliminarea / reducerea zgomotului

Motivație: reducerea de zgomot

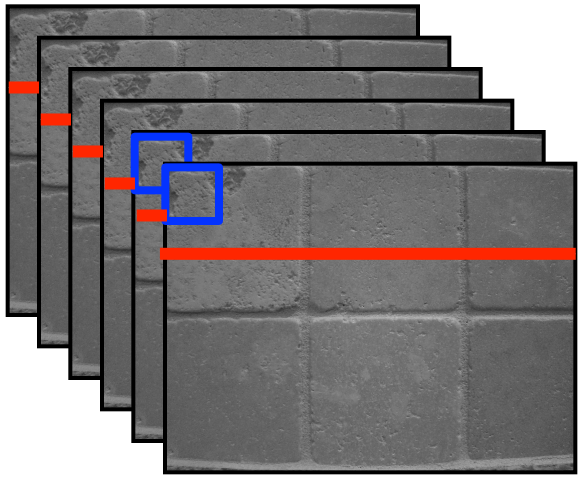

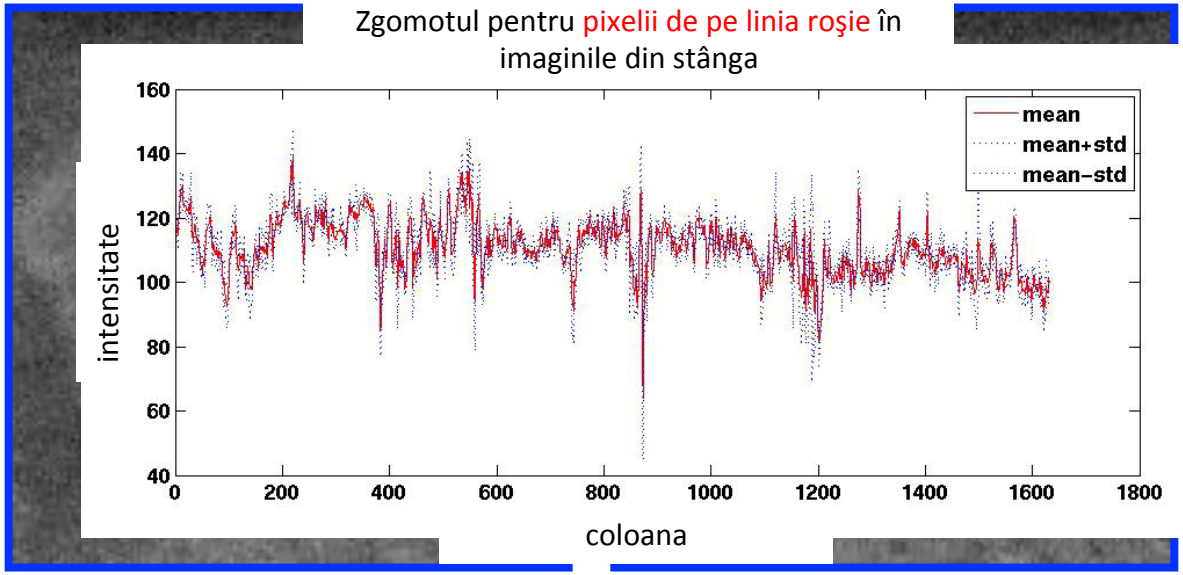

- Imperfecțiuni tehnologice ale senzorilor de imagine

$$I(x,y) = \hat{I}(x,y) + \eta(x,y)$$

imagine obținută imagine ideală zgomot

- Imagini multiple ale **aceleaşi scene statice** nu vor fi identice

Slide adaptat după K. Grauman

Tipuri de zgomot

imagine originală

Slide adaptat după Steve Seitz

Distributia normală 1D
(clopotul lui Gauss)

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

μ - medie
(deplasarea distribuției)

σ - deviație standard
(împrăştierea distribuției)

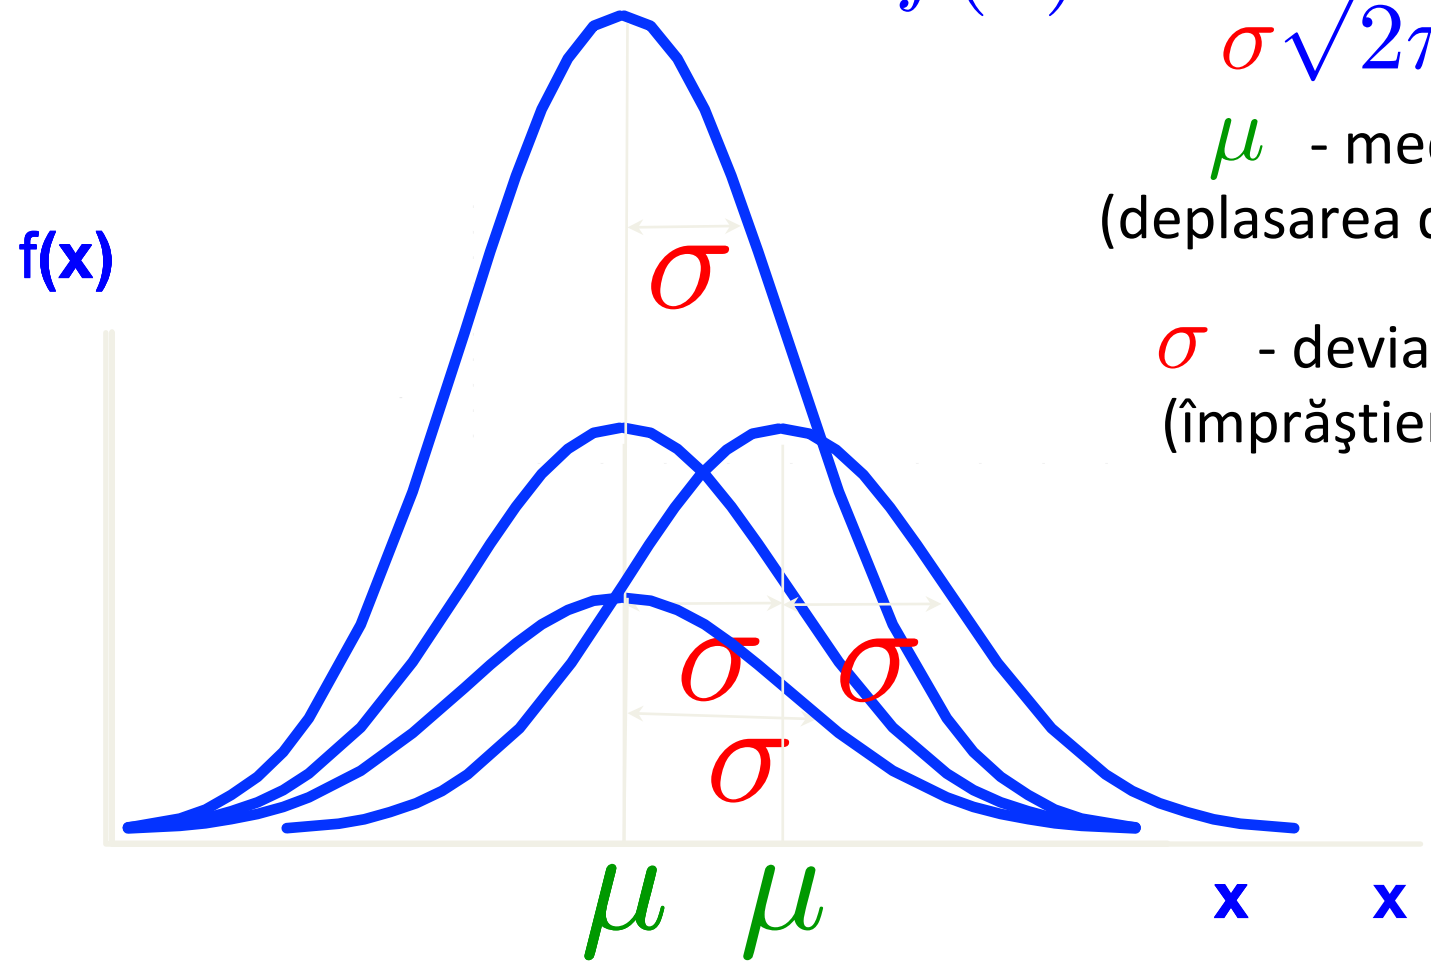

Regula 68-95-99.7

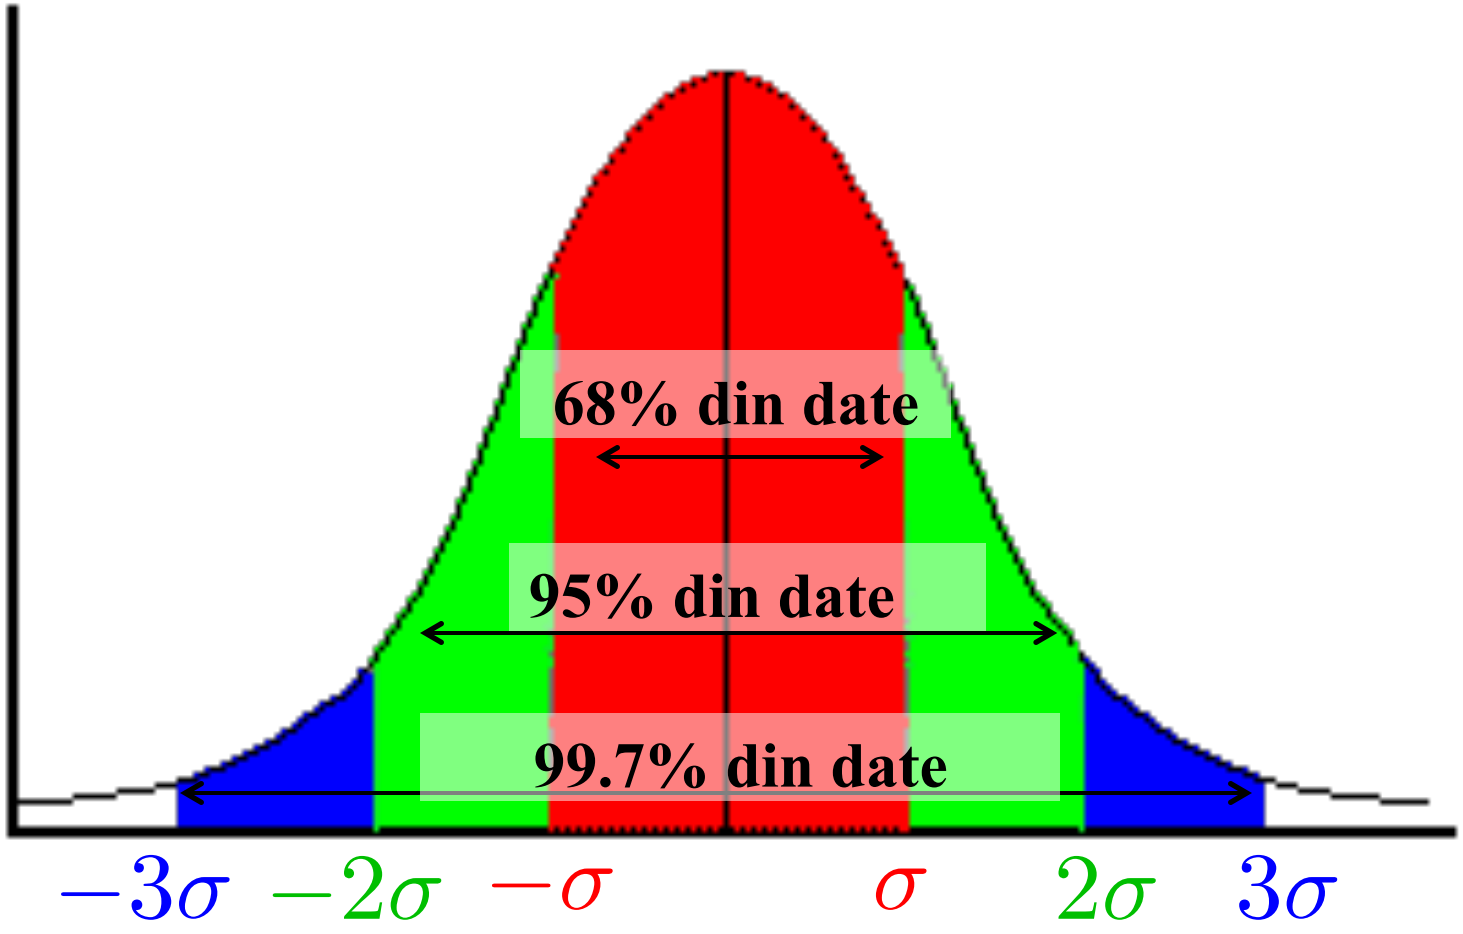

Zgomot normal – efectul lui σ

sigma = 1

sigma = 5

sigma = 25

Motivație: reducerea de zgomot

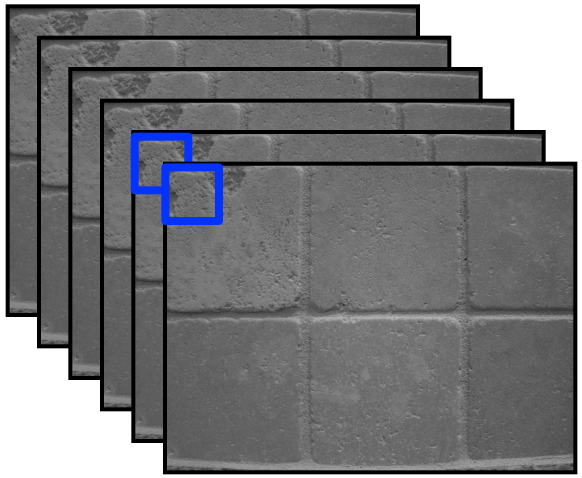

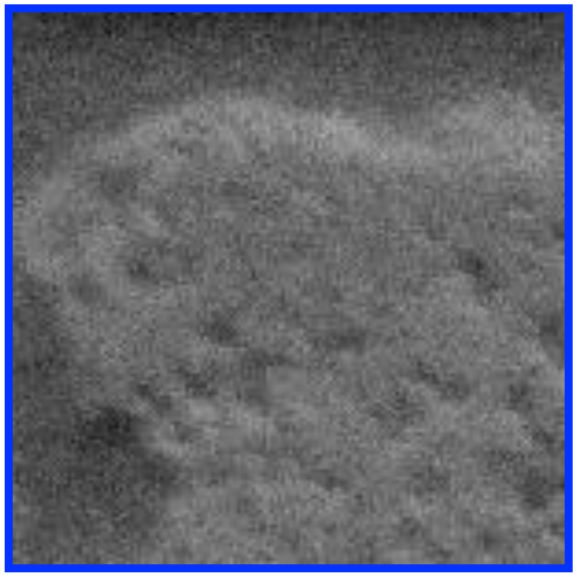

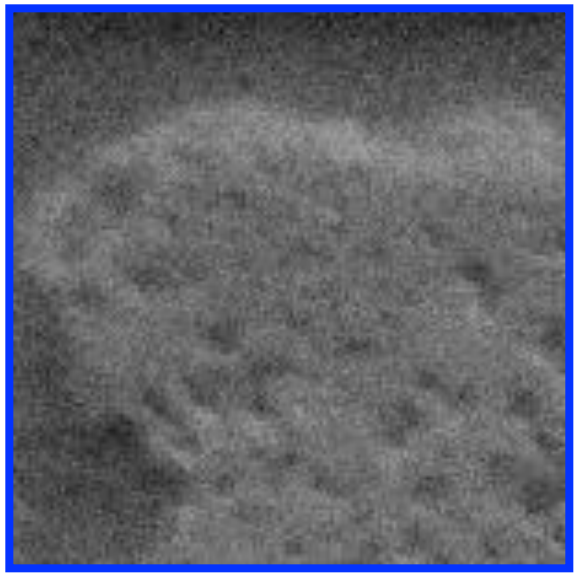

- Chiar şi imagini multiple ale **aceleaşi scene statice** nu vor fi identice.
- Cum putem reduce zgomotul, adică să estimăm adevăratele intensități?
- Dacă avem mai multe imagini luăm media
- **Dar dacă avem numai o singură imagine?**

Slide adaptat după K. Graumann

O posibilă soluție

- Ipoteze:
  - pixelii “vecini” nu diferă prea mult între ei
  - zgomotul care afectează pixelii este independent
- Soluție:
  - înlocuim valoarea fiecărui pixel cu media valorilor pixelilor din “vecinătatea” lui

O posibilă soluție

- Înlocuim valoarea fiecărui pixel cu media valorilor pixelilor din vecinătatea lui
- Exemplu în 1D:

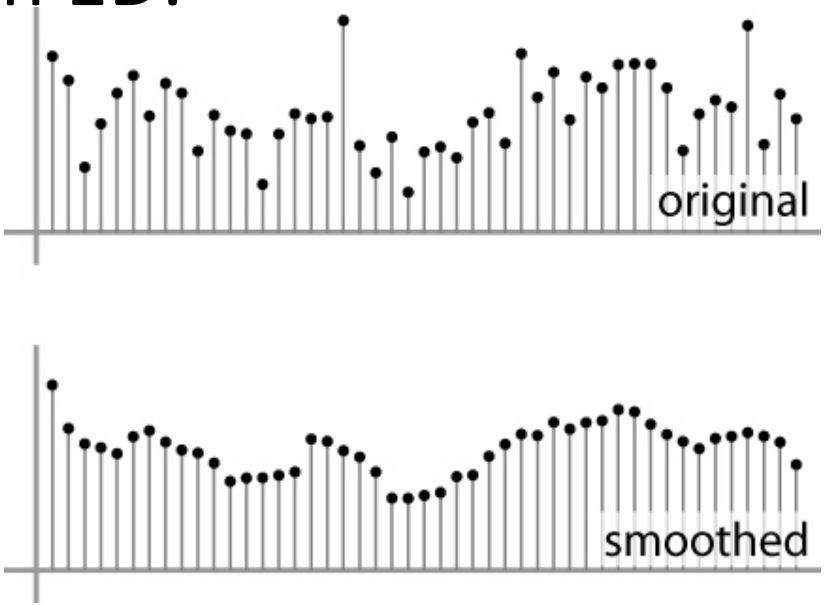

Slide adaptat după S. Marschner

Medie ponderată

- Putem adaugă ponderi pentru fiecare pixel
- *Ponderi* [1, 1, 1, 1, 1] / 5

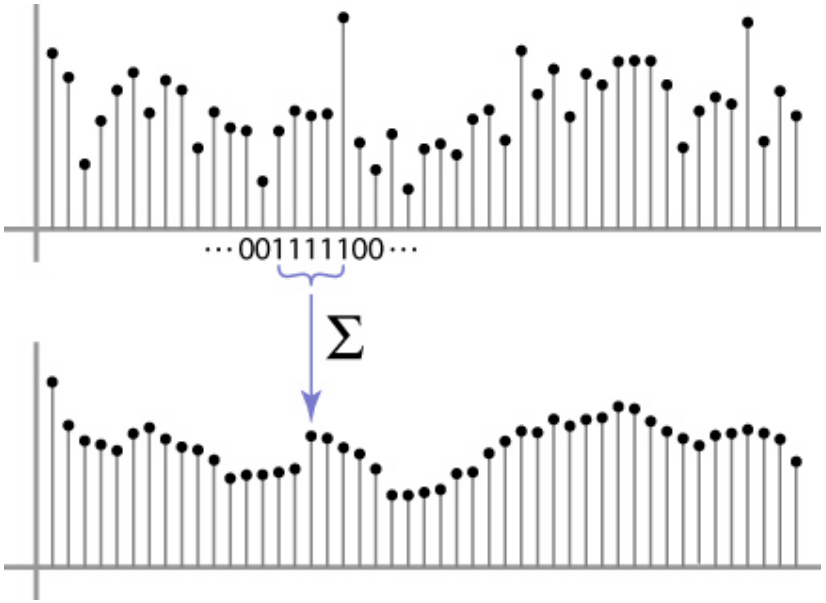

Slide adaptat după S. Marschner

Medie ponderată

- Ponderi ne-uniforme [1, 4, 6, 4, 1] / 16

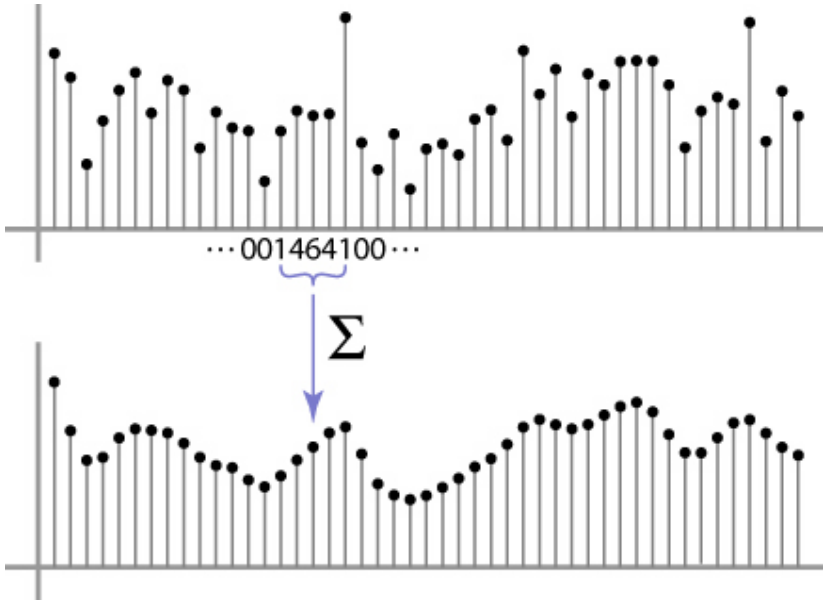

Slide adaptat după S. Marschner

Medie în 2D

$I[x, y]$

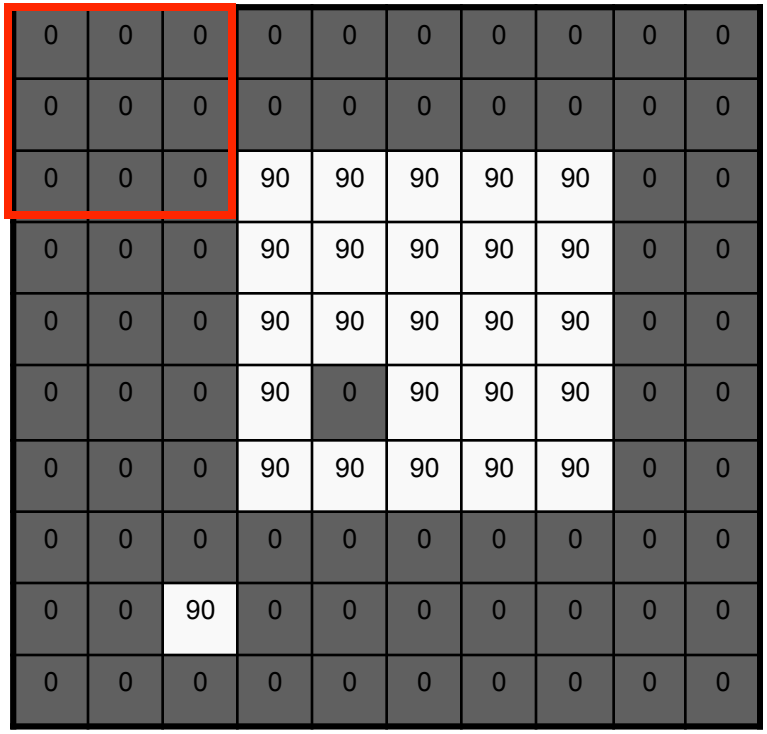

$O[x, y]$

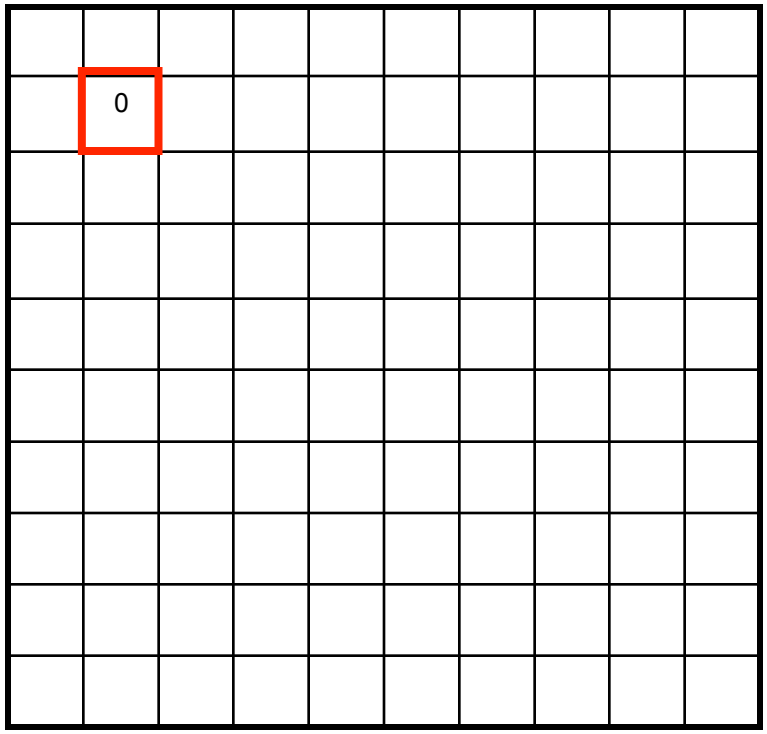

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

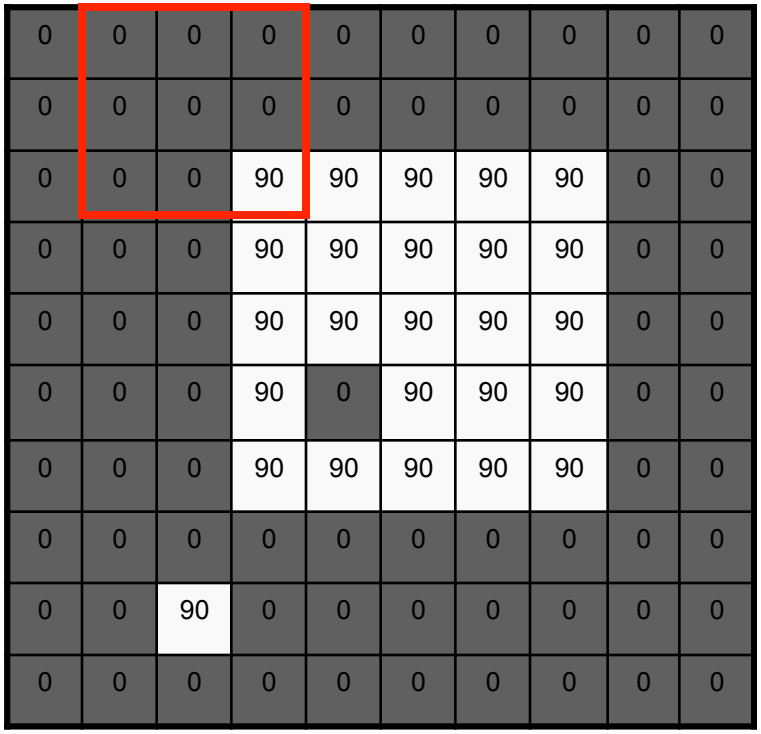

$O[x, y]$

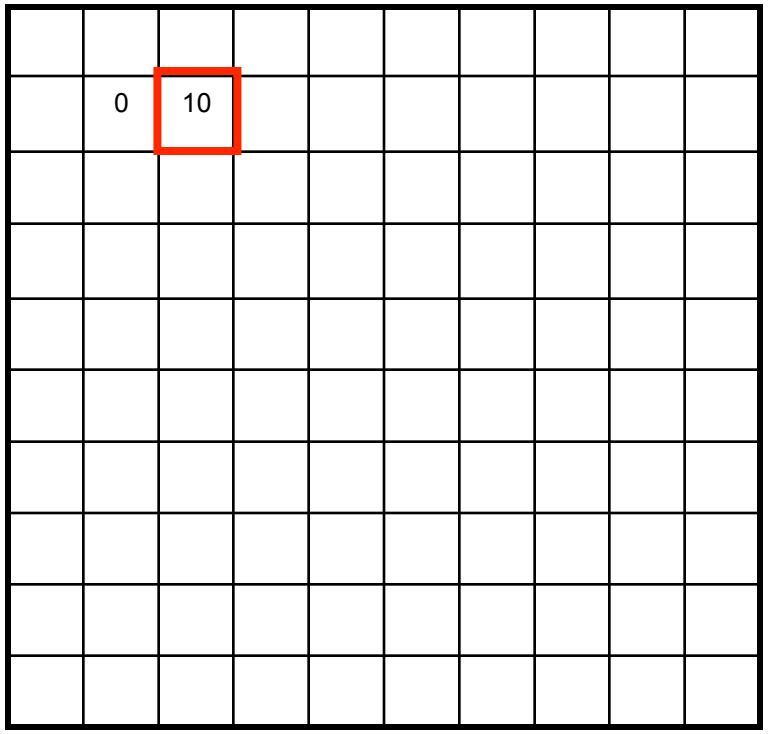

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

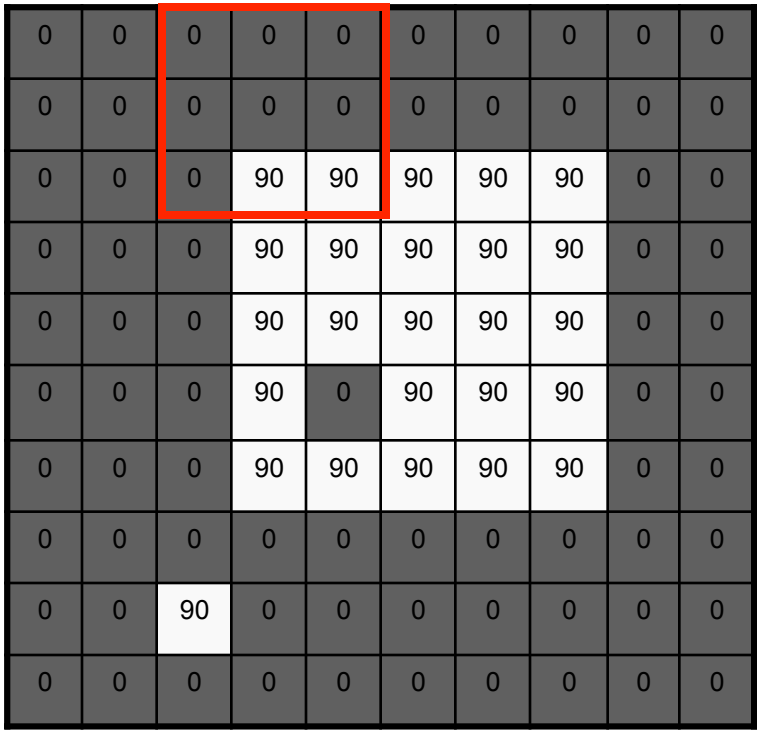

$O[x, y]$

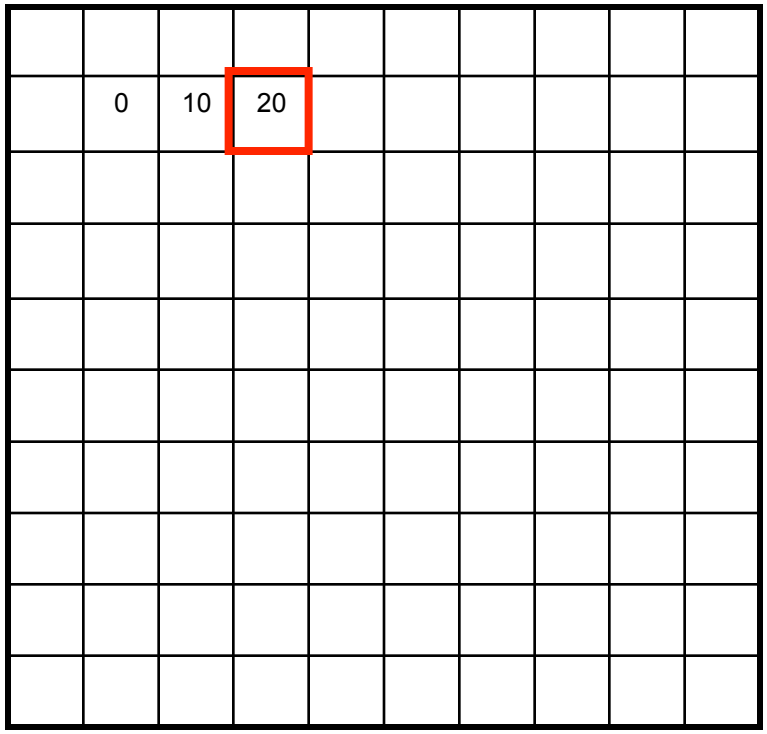

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$O[x, y]$

	0	10	20	30					

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$O[x, y]$

	0	10	20	30	30				

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$O[x, y]$

	0	10	20	30	30				
							?		

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$O[x, y]$

	0	10	20	30	30				
							60		

Slide adaptat după Steve Seitz

Medie în 2D

$I[x, y]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$O[x, y]$

	0	10	20	30	30	30	20	10	
	0	20	40	60	60	60	40	20	
	0	30	60	90	90	90	60	30	
	0	30	50	80	80	90	60	30	
	0	30	50	80	80	90	60	30	
	0	20	30	50	50	60	40	20	
	10	20	30	30	30	30	20	10	
	10	10	10	0	0	0	0	0	

Slide adaptat după Steve Seitz

Corelație

- Pentru o vecinătate de dimensiuni 2k+1 x 2k+1:

$$O[i,j] = \underbrace{\frac{1}{(2k+1)^2}}_{\text{pondere egală pentru fiecare pixel}} \underbrace{\sum_{u=-k}^{k} \sum_{v=-k}^{k} I[i+u, j+v]}_{\text{toți pixelii din vecinătatea pixelului (i,j) din imaginea I}}$$

(i-k,j-k)				(i-k,j+k)
		(i,j)		
(i+k,j-k)				(i+k,j+k)

Vecinătate de dimensiuni (2k +1) x (2k+1) centrată în (i,j)

Slide adaptat după K. Grauman

Corelație

- Pentru o vecinătate de dimensiuni 2k+1 x 2k+1:

$$O[i,j] = \underbrace{\frac{1}{(2k+1)^2}}_{\text{pondere egală pentru fiecare pixel}} \underbrace{\sum_{u=-k}^{k}\sum_{v=-k}^{k} I[i+u, j+v]}_{\text{toți pixelii din vecinătatea pixelului (i,j) din imaginea I}}$$

- Generalizăm pentru a permite ponderi diferite:

$$O[i,j] = \sum_{u=-k}^{k}\sum_{v=-k}^{k} \underbrace{F[u,v]}_{\text{ponderi ne-uniforme}} I[i+u, j+v]$$

Slide adaptat după K. Grauman

Corelație

$$O[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} F[u,v] I[i+u, j+v]$$

Corelație: $O = F \otimes I$

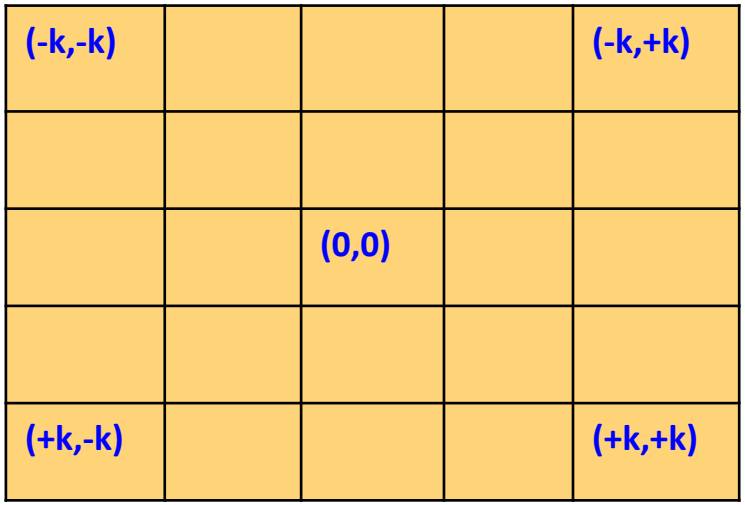

Filtrul F de dimensiuni (2k +1) x (2k+1) centrat în (0,0)

Slide adaptat după K. Grauman

Corelație

$$O[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} F[u,v] I[i+u, j+v]$$

Corelație: $O = F \otimes I$

Filtrarea (liniară a) unei imagini: înlocuim fiecare pixel cu o combinație (liniară) a “vecinilor” săi.

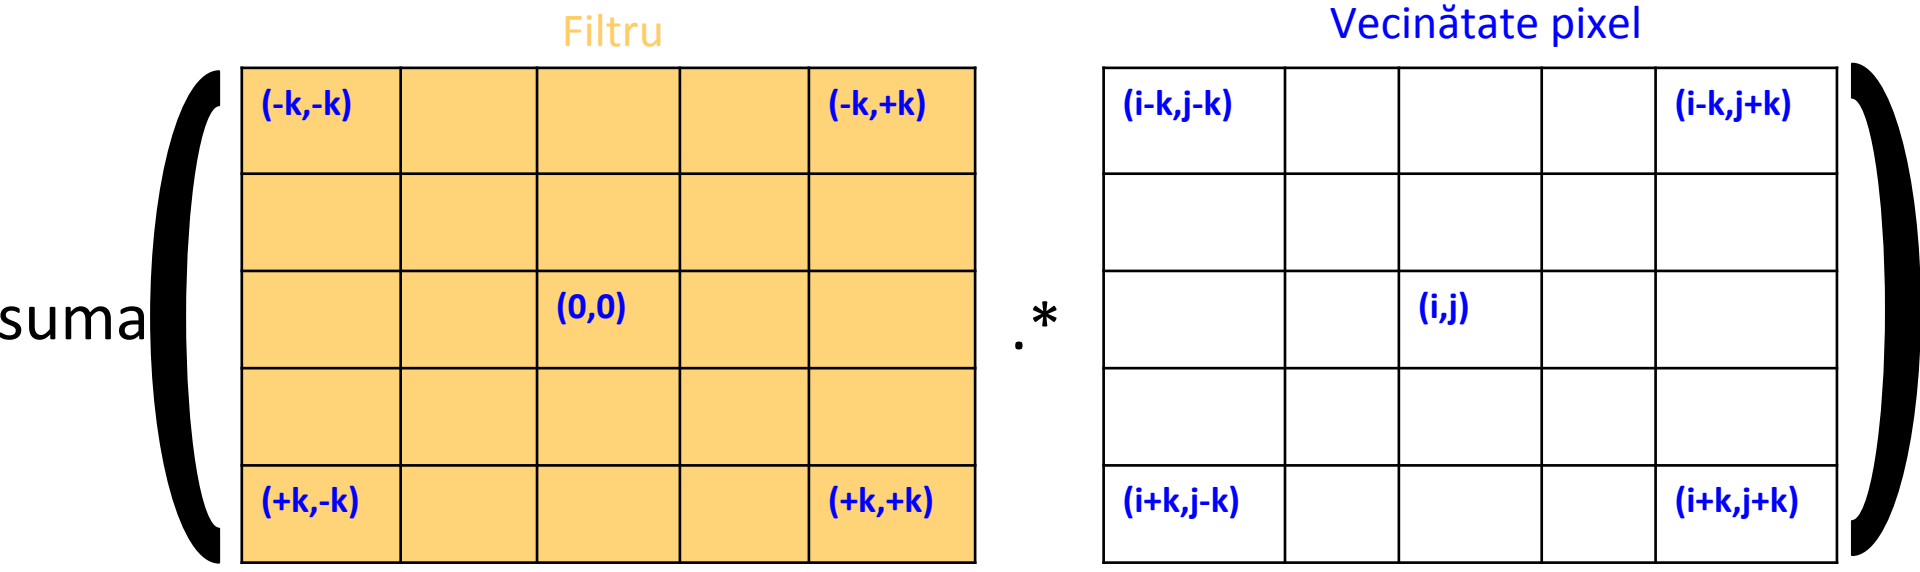

Corelație

$$O[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} F[u,v] I[i+u, j+v]$$

Corelație: $O = F \otimes I$

Filtrarea (liniară a) unei imagini: înlocuim fiecare pixel cu o combinație (liniară) a “vecinilor” săi.

F se mai numeşte filtru, kernel, mască (de filtrare).

Filtrul F - conține ponderile pixelilor folosiți în combinația (liniară).

Filtrul de medie

- Ce ponderi are filtrul *F* pentru exemplul precedent (medie în 2D)?

$F[u,v]$ $\otimes$ $I[x,y]$ $O[x,y]$

$\frac{1}{9}$

1	1	1
1	?	1
1	1	1

filtru de medie (filtru pătrat)

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

	0	10	20	30	30				

$$O = F \otimes I$$

Slide adaptat după Steve Seitz

Blurarea (netezirea) unei imagini cu un filtru de medie

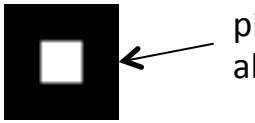

pictograma pentru filtru de medie:
alb = valoare mare, negru = valoare mică

Imagine inițială

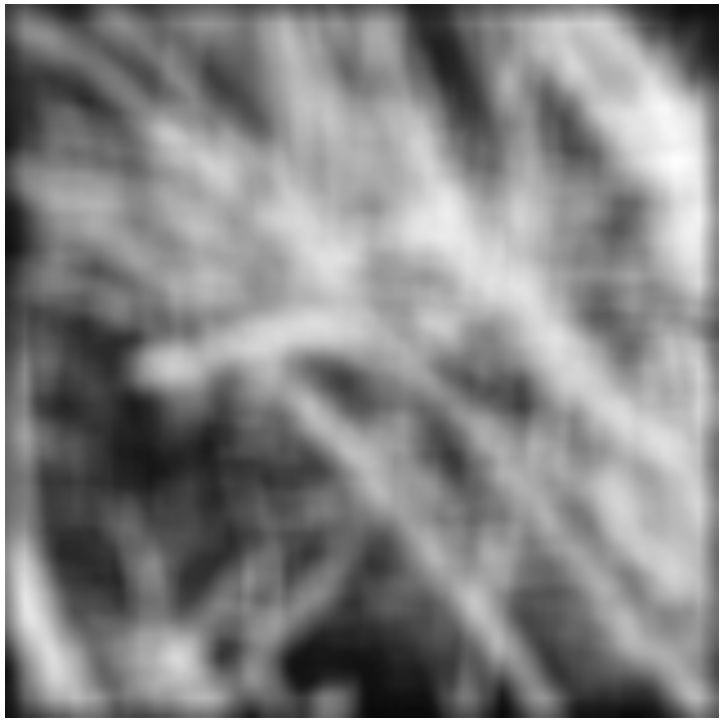

Imagine filtrată

Dimensiune output

- Care este dimensiunea imaginii filtrate?

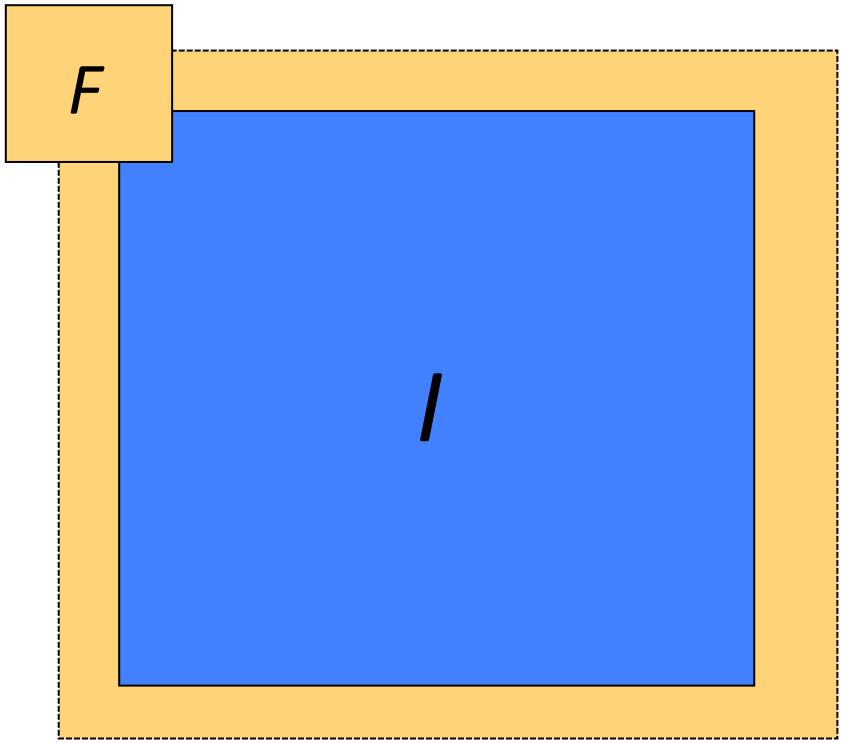

Dimensiune output

- Care este dimensiunea imaginii filtrate?
- PYTHON: scipy.signal.convolve2d
- opțiuni pentru filtrare
  - 'full': dim(O) = dim(I) + dim(F)
  - 'same': dim(O) = dim(I)
  - 'valid': dim(O) = dim(I) – dim(F)

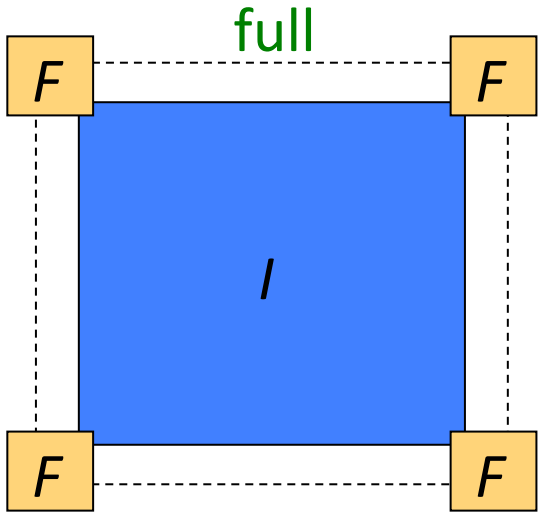

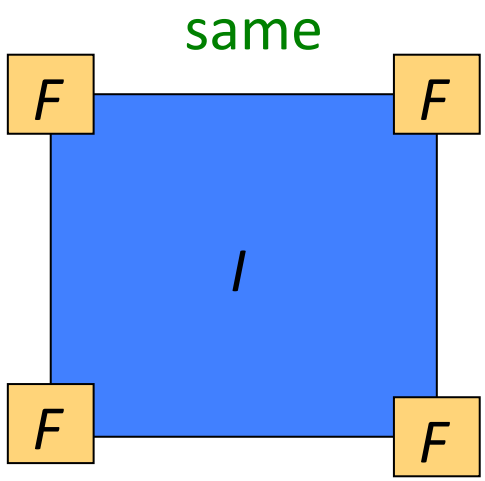

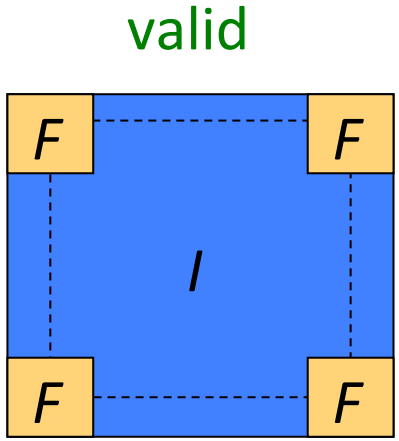

Slide adaptat după S. Lazebnik

Pixelii din afara imaginii

- Ce valori au pixelii din afara imaginii ?

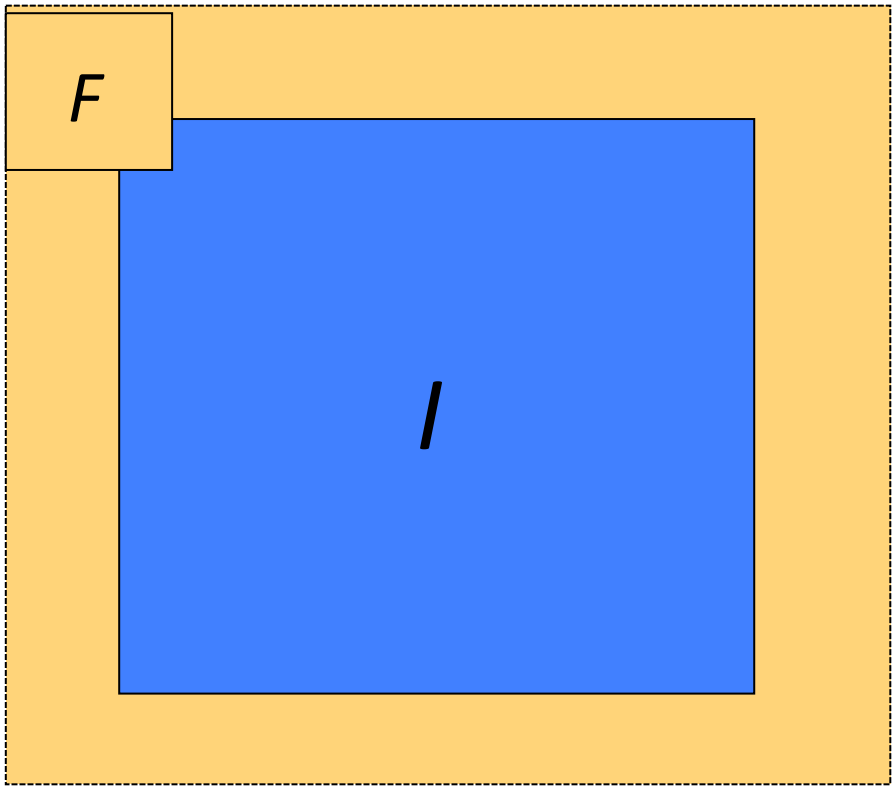

- Fereastra filtrului depăseste marginea imaginii

Slide adaptat după S. Marschner

Pixelii din afara imaginii

- Ce valori au pixelii din afara imaginii ?
  - extrapolăm valori
  1. pixeli = 0 (negru)
  2. copiază pixelii în mod circular
  3. copiază pixelii de la marginea imaginii
  4. oglindeşte pixelii de la marginea imaginii

Slide adaptat după S. Marschner

Filtru normal (Gaussian)

- Cei mai apropiați pixeli vecini au o pondere mai mare în imaginea filtrată

Acest filtru aproximează distribuția normală în 2D:

$$f(u,v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{2\sigma^2}}$$

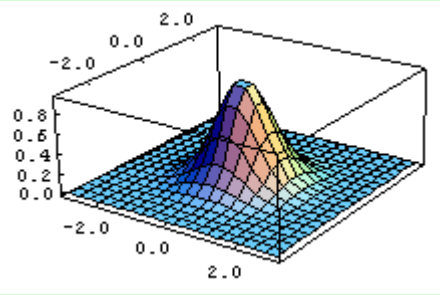

$$\frac{1}{16}$$

1	2	1
2	4	2
1	2	1

$F[u,v]$

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	90	0	90	90	90	0	0
0	0	0	90	90	90	90	90	0	0
0	0	0	0	0	0	0	0	0	0
0	0	90	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

$I[x,y]$

Slide adaptat după Steve Seitz

Filtru normal (Gaussian)

- Cei mai apropiați pixeli vecini au o pondere mai mare în imaginea filtrată

Acest filtru aproximează distribuția normală în 2D:

$$f(u,v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{2\sigma^2}}$$

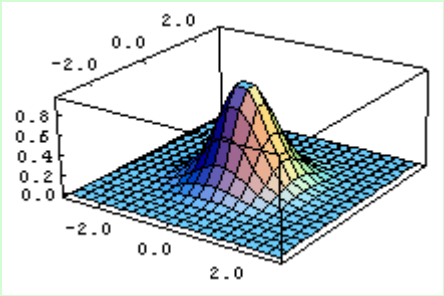

$$\frac{1}{16}$$

1	2	1
2	4	2
1	2	1

$F[u,v]$

0	0	0	0	0	0	0	0	0	0
0	0	6	17	23	23	23	17	6	0
0	0	17	51	68	68	68	51	17	0
0	0	23	68	90	90	90	68	23	0
0	0	23	62	79	84	90	68	23	0
0	0	23	56	68	79	90	68	23	0
0	0	17	45	56	62	68	51	17	0
0	6	17	23	23	23	23	17	6	0
0	11	23	11	0	0	0	0	0	0
0	6	11	6	0	0	0	0	0	0

$I[x,y]$

Slide adaptat după Steve Seitz

Blurarea unei imagini

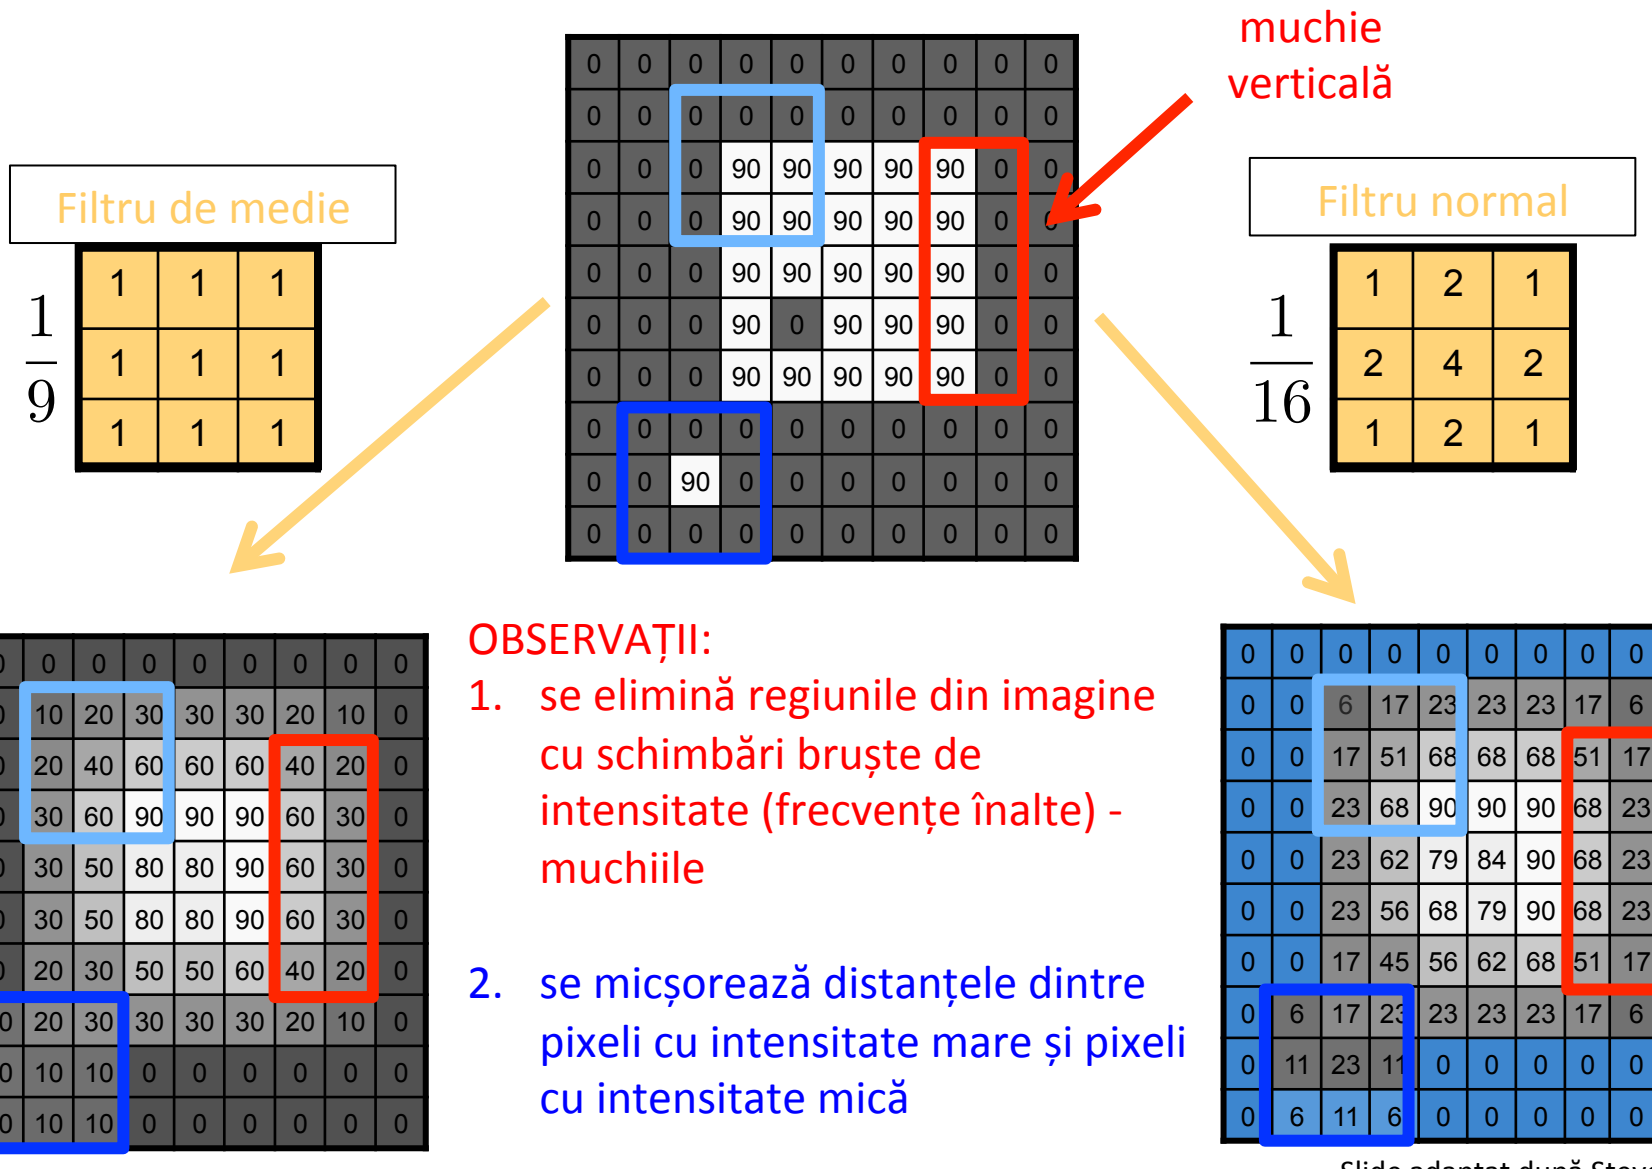

Slide adaptat după Steve Seitz

Blurarea unei imagini

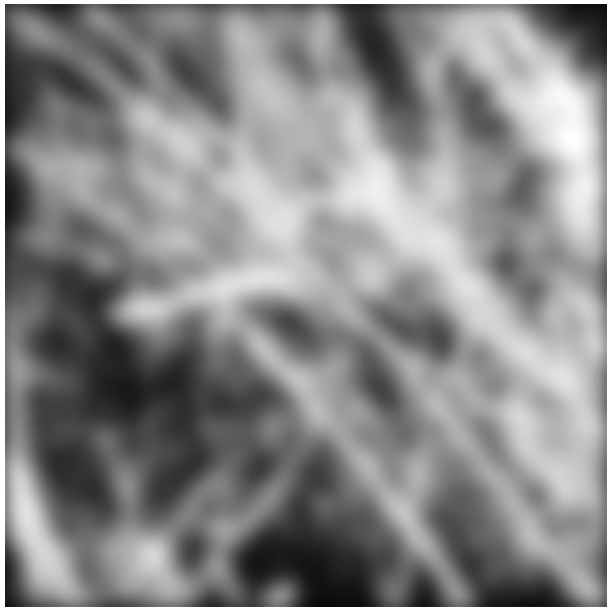

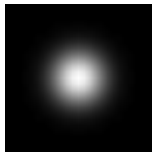

filtru Gaussian:
alb = valoare mare,
negru = valoare mică

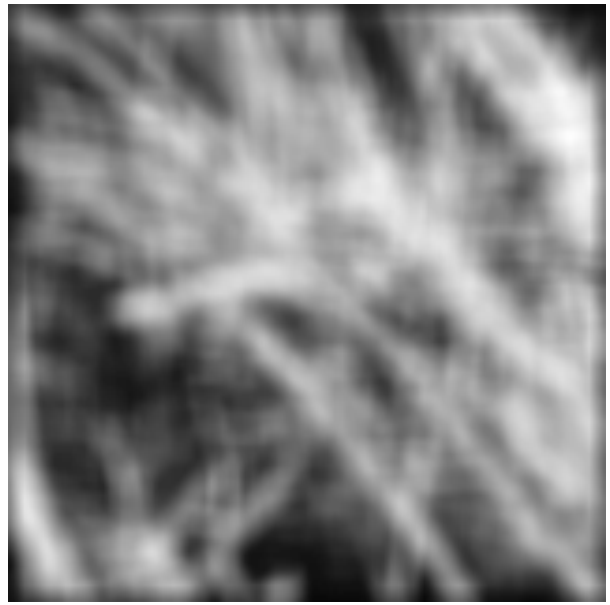

filtru de medie

Filtre normale (Gaussiene)

- Care sunt parametri ce definesc filtrul?

1. **Dimensiunea**
   - funcțiile normale (Gaussiene) au suport infinit (> 0), însă filtrele au dimensiune finită

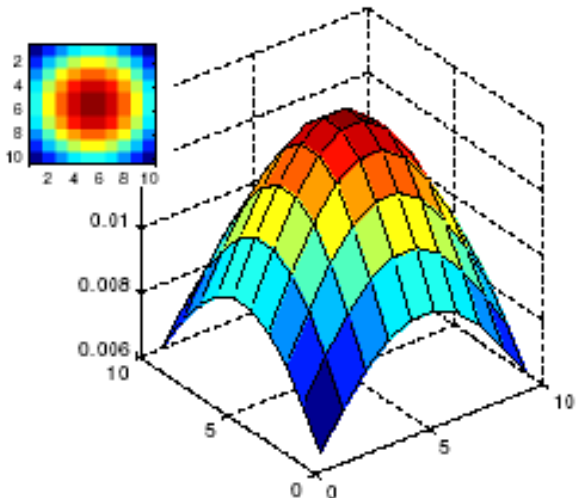

σ = 5

10 x 10

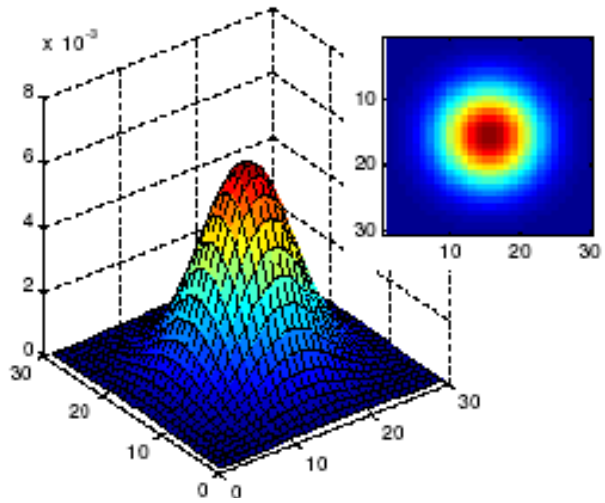

σ = 5

30 x 30

Slide adaptat după K. Grauman

Filtre normale (Gaussiene)

- Care sunt parametri ce definesc filtrul?

2. Deviația standard: cât de “neted” e filtrul

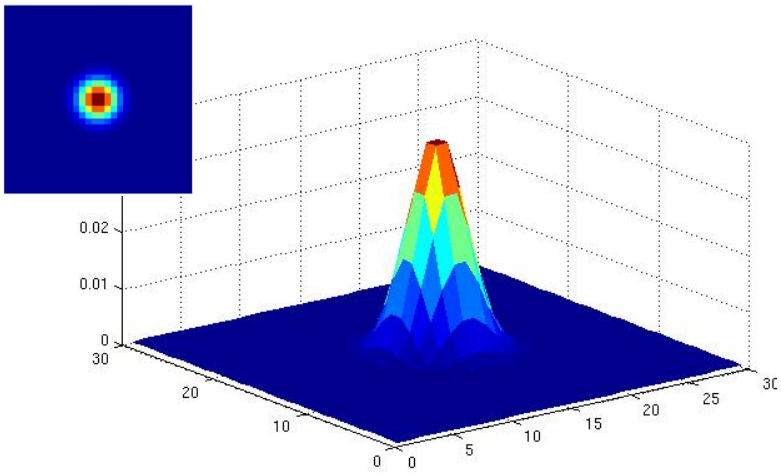

σ = 2

30 x 30

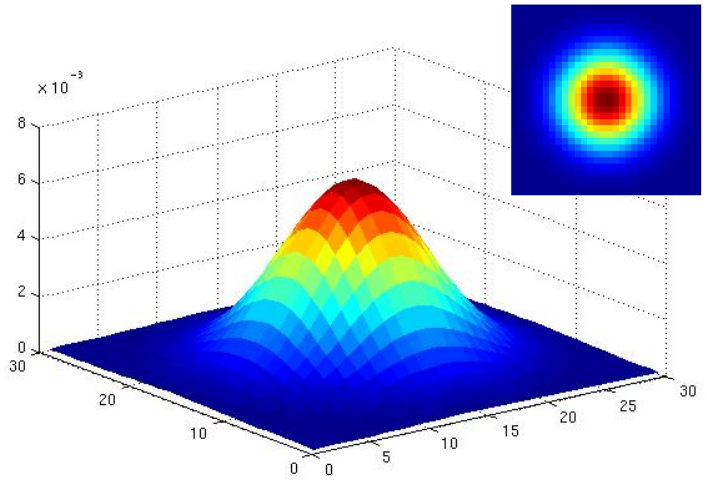

σ = 5

30 x 30

Slide adaptat după K. Grauman

Blurarea unei imagini cu un filtru Gaussian

Parametrul σ – controlează “netezimea” filtrului

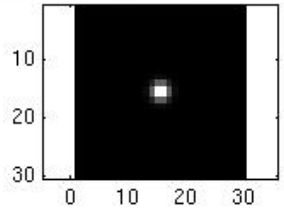

σ = 1

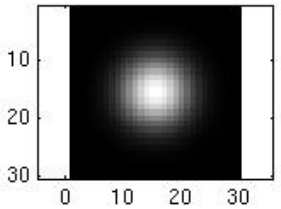

σ = 4

...

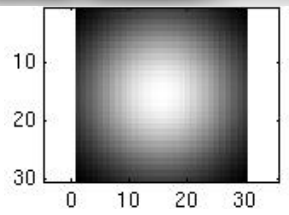

σ = 10

Slide adaptat după K. Grauman

Proprietăți ale filtrelor de blurare ("smoothing")

1. valori pozitive;

2. suma lor = 1 → pentru regiuni constante (toți pixelii au aceeași valoare → perete alb), output = input;

3. gradul de blurare/netezire este proporțional cu dimensiunea filtrului;

4. elimină regiunile de pixeli cu variantă mare în intensitate (frecvențe înalte); se mai numesc filtre trece-jos ("low-pass")

Proprietăți ale filtrelor de blurare (“smoothing”)

ce se întâmplă (ce caracteristici are imaginea rezultată) dacă avem un filtru de blurare care nu este normalizat (suma elementelor filtrului ≠ 1)?

1	1	1
1	1	1
1	1	1

⊗

=

Dacă suma elementelor filtrului > 1 → imaginea se luminează
Dacă suma elementelor filtrului < 1 → imaginea se întunecă